

# Intro & Vorstellungsrunde

GRK2700 Statistik-Workshop  
am 24. August 2026

Dr. Dominic Schmitz  
[dominic.schmitz@hhu.de](mailto:dominic.schmitz@hhu.de)


# Wer bin ich?

- Dr. Dominic Schmitz
- Postdoc @ English Language and Linguistics, Anglistik und Amerikanistik, Heinrich-Heine-Universität Düsseldorf
- Forschungsgebiete  
Akustische Phonetik, Distributionelle Semantik, Genderlinguistik, Morpho-Phonetik, Psycholinguistik (experimentell & computational)
- Seit 2018: zahlreiche Workshops/Veranstaltungen zur statistischen Analyse empirischer Daten in der Linguistik

# Wer bin ich?

- Dr. Dominic Schmitz
- Postdoc @ English Language and Linguistics, Anglistik und Amerikanistik, Heinrich-Heine-Universität Düsseldorf
- Forschungsgebiete  
Akustische Phonetik, Distributionelle Semantik, Genderlinguistik, Morpho-Phonetik, Psycholinguistik (experimentell & computational)
- Seit 2018: zahlreiche Workshops/Veranstaltungen zur statistischen Analyse empirischer Daten in der Linguistik

**Und wer seid ihr?**



Join at [slido.com](https://slido.com)  
**#2168821**

① The Slido app must be installed on every computer  
you're presenting from



# Wie würdest du deine aktuelle Beziehung zu Statistik beschreiben?



**Wie sicher fühlst du dich aktuell dabei, eine passende statistische Analyse für eine Forschungsfrage auszuwählen?**



# Welche dieser Analysen hast du selbst schon einmal durchgeführt?





# Was ist bei statistischen Analysen für dich momentan am schwierigsten?

① The Slido app must be installed on every computer  
you're presenting from



# Welche Art von Daten begegnet dir in deiner eigenen Forschung am häufigsten?



**Wenn du jetzt deine eigenen Daten analysieren müsstest: An welcher Stelle würdest du vermutlich zuerst hängenbleiben?**



# Was wäre für dich am Ende dieser zwei Tage ein Erfolg?

# Ein paar Vorbemerkungen

- Statistik ist selten „so und nicht anders“
  - Für dieselbe Forschungsfrage können mehrere vertretbare Analysewege existieren
  - Entscheidend ist, dass die Modellierung zur Forschungsfrage, zum Design und zu den Daten passt und begründet werden kann
- Statistische Praxis entwickelt sich weiter
  - Empfehlungen, Konventionen und „best practices“ verändern sich
  - Was vor zehn oder zwanzig Jahren Standard war, muss heute nicht mehr die bevorzugte Vorgehensweise sein
  - Was wir heute und morgen besprechen, ist vielleicht schon nächstes Jahr teils überholt

# Ein paar Vorbemerkungen

- Regeln sind häufig Heuristiken, keine Naturgesetze
  - Viele Schwellenwerte und Faustregeln helfen bei Entscheidungen, ersetzen aber nicht die inhaltliche Beurteilung
- Ein Modell ist immer eine Vereinfachung
  - Wir versuchen nicht, die Realität vollständig abzubilden, sondern eine Forschungsfrage mit einem möglichst sinnvollen, interpretierbaren Modell zu beantworten
- Komplexer ist nicht automatisch besser
  - Höhere Komplexität macht ein Modell nicht automatisch wissenschaftlich überzeugender
  - Modellkomplexität sollte einen Grund haben

# Ein paar Vorbemerkungen

- Ein signifikanter Effekt ist nicht automatisch ein wichtiger Effekt
  - p-Werte sind nur ein Teil der Interpretation
  - Effektgröße, Unsicherheit, Forschungsdesign und inhaltliche Bedeutung gehören genauso dazu
- „Nicht signifikant“ bedeutet nicht „kein Effekt“
  - Fehlende Evidenz für einen Effekt ist nicht dasselbe wie Evidenz für die Abwesenheit eines Effekts
- Statistik beginnt vor dem R-Code
  - Forschungsfrage → Design → Variablen → Datenstruktur → Modell
  - Die wichtigste Entscheidung ist häufig nicht, welchen Befehl wir in R verwenden, sondern welches Modell unsere Frage eigentlich repräsentiert

# Ein paar Vorbemerkungen

- Software trifft keine wissenschaftlichen Entscheidungen für uns
  - R kann ein Modell rechnen
  - Ob das Modell sinnvoll spezifiziert ist und was das Ergebnis bedeutet, müssen wir entscheiden
- Fehlermeldungen gehören dazu
  - Auch erfahrene R-Nutzer\*innen recherchieren Fehlermeldungen, lesen Dokumentationen und probieren Dinge aus
  - Ziel ist nicht, jeden Befehl auswendig zu kennen, sondern Probleme systematisch lösen zu können
- Wir werden bewusst nicht alles behandeln
  - Zwei Tage reichen nicht für „Statistik“; einige eurer Wünsche werden wir daher nur streifen oder gar nicht bearbeiten können



# Ein paar Vorbemerkungen

- Das Ziel ist ein Fundament, kein vollständiger Werkzeugkasten
  - Nach dem Workshop solltet ihr neue Verfahren leichter selbst erschließen können: Was macht dieses Modell? Wann ist es sinnvoll? Wie prüfe ich es? Wie interpretiere und kommuniziere ich die Ergebnisse?
- Fragen sind ausdrücklich erwünscht – auch solche, die uns vom geplanten Weg abbringen
  - Gerade Verständnisfragen zeigen oft, an welchen Stellen statistische Konzepte nur scheinbar selbstverständlich sind
- Und: Ihr müsst nach diesen zwei Tagen nicht alles können
  - Wenn ihr anschließend besser einschätzen könnt, welche Frage ihr stellen müsst und wo ihr nach einer Antwort suchen könnt, ist bereits sehr viel gewonnen


# Disclaimer

- Wir lernen Prinzipien, nicht Rezepte
  - Bitte nehmt aus diesem Workshop keine neuen Kochrezepte mit, sondern Entscheidungslogiken
- Vieles, was wir besprechen, wird zwangsläufig vereinfacht
  - Hinter fast jedem Thema dieses Workshops steckt eine eigene methodische Literatur
  - Ziel ist zunächst ein belastbares konzeptuelles Verständnis, nicht die vollständige Behandlung aller Spezialfälle


# Mein Angebot

- Wer irgendwann Statistik mit mir gelernt hat, darf mir auch später gerne konkrete Fragen per Mail schicken
- Ich kann nicht versprechen, jedes Analyseproblem vollständig zu lösen, aber ich helfe gerne dabei, einen sinnvollen nächsten Schritt zu finden


# R in RStudio




# R in RStudio




# R in RStudio



# R in RStudio




# R in RStudio







# R in RStudio



# R in RStudio



# R in RStudio



# Das SfL Package

- Ein R-Package extra für „Statistics for Linguistics“/„Statistik für Linguistik“ Kurse und Workshops entwickelt

```
1 install.packages("remotes")  
2 remotes::install_github("dosc91/SfL")
```

# Unsere Daten

- 60 Versuchspersonen bearbeiten jeweils 120 Wörter in einer Lexical-Decision-Aufgabe; jede Person sieht jedes Wort
- Zunächst erscheint ein Kontextwort, anschließend das eigentliche Zielwort
- Manche Zielwörter erscheinen nach einem semantisch verwandten Kontext (related), andere nach einem nicht verwandten Kontext (unrelated)
- Die Wörter unterscheiden sich außerdem unter anderem hinsichtlich ihrer Frequenz, Länge und lexikalischen Nachbarschaft
- **Frage: Was macht ein Wort schnell und zuverlässig erkennbar?**

# Unsere Daten

- Für jedes einzelne Trial kennen wir
  - `RT` Reaktionszeit auf das Zielwort
  - `accuracy` War die Antwort korrekt?
  - `condition` semantisch verwandter vs. nicht verwandter Kontext
  - `frequency` Wortfrequenz
  - `length` Länge des Zielworts
  - `neighbourhood` Dichte der lexikalischen Nachbarschaft
  - `group` Trainings- vs. Kontrollgruppe
  - `trial` Position des Trials im Experiment
  - `subject` Versuchsperson
  - `item` Zielwort

# Unsere Daten

- Wort-Eigenschaften
  - Werden häufigere Wörter schneller erkannt?
  - Werden längere Wörter langsamer verarbeitet?
  - Spielt die lexikalische Nachbarschaft eines Wortes eine Rolle?
- Experimentelle Manipulationen
  - Werden Wörter nach einem semantisch verwandten Kontext schneller erkannt?
  - Unterscheidet sich die Trainingsgruppe von der Kontrollgruppe?
  - Ist der Frequenzeffekt in der related- und unrelated-Bedingung gleich stark?
- Weitere Fragen
  - Welche Faktoren erhöhen die Wahrscheinlichkeit einer korrekten Antwort?
  - Verändern sich Reaktionszeiten im Verlauf des Experiments durch Übung oder Ermüdung?
  - Wie stark unterscheiden sich Versuchspersonen und Wörter voneinander?

**Fragen?**