

Lineare Regression

GRK2700 Statistik-Workshop
am 24. August 2026

Dr. Dominic Schmitz
dominic.schmitz@hhu.de

Lineare Regression: Formel

kontinuierliche
abhängige Variable

unabhängige
Prädiktorvariable


$$Y = \beta_0 + \beta_1 X + \epsilon$$

Steigung/
Slope


Residuen/
Error Term

y-Achsenabschnitt/
Intercept


Lineare Regression: Formel




Lineare Regression: Formel




Lineare Regression: Formel




Lineare Regression: Formel



Lineare Regression: Formel



Lineare Regression: Formel



Lineare Regression in R

- In R erstellt man ein einfaches lineares Regressionsmodell

$$Y = \beta_0 + \beta_1 X + \epsilon$$

- mit folgendem Befehl und folgender Syntax

```
1 lm(Y ~ X, data)
```

- y-Achsenabschnitt und Steigung berechnet R, indem es die Summe der quadrierten Residuen zwischen tatsächlichen Datenpunkten und der Regressionsgeraden minimiert

Lineare Regression in R

- Beispiel: RT modelliert durch frequency

```
1 model = lm(RT ~ frequency, data)
```

- Nach der Berechnung erhalten wir folgende Information zum Modell

```
1 Call:
2 lm(formula = RT ~ frequency, data = data)
3
4 Coefficients:
5 (Intercept)  frequency
6      640.72      -52.19
```

Lineare Regression in R

- Beispiel: RT modelliert durch frequency

```
1 model = lm(RT ~ frequency, data)
```

- Nach der Berechnung erhalten wir folgende Information zum Modell

```
1 Call:
2 lm(formula = RT ~ frequency, data = data)
3
4 Coefficients:
5 (Intercept) 640.72 frequency -52.19
6
```

Achsenabschnitt Steigung

Lineare Regression in R

- Einen p-Wert erhalten wir mit der `anova()` Funktion

```
1 Analysis of Variance Table
2
3 Response: RT
4           Df      Sum Sq  Mean Sq F value    Pr(>F)
5 frequency_z    1  17114356 17114356   568.37 < 2.2e-16 ***
6 Residuals  7198 216739855     30111
7 ---
8 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- Diese führt einen F-Test durch: Er prüft, ob das Modell mit dem untersuchten Faktor die Daten besser erklärt als ein Modell ohne diesen Faktor
- Der F-Wert setzt die durch den Faktor erklärte Streuung ins Verhältnis zur unerklärten Streuung („Rauschen“) in den Daten

Lineare Regression in R

```
1 Analysis of Variance Table
2
3 Response: RT
4      Df      Sum Sq   Mean Sq F value    Pr(>F)
5 frequency_z    1 17114356 17114356   568.37 < 2.2e-16 ***
6 Residuals 7198 216739855     30111
7 ---
8 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- **Df (Degrees of Freedom / Freiheitsgrade)**

Gibt an, wie viele unabhängige Informationen für die Berechnung des jeweiligen Effekts bzw. der Reststreuung zur Verfügung stehen

Lineare Regression in R

```
1 Analysis of Variance Table
2
3 Response: RT
4           Df Sum Sq Mean Sq F value    Pr(>F)
5 frequency_z  1 17114356 17114356  568.37 < 2.2e-16 ***
6 Residuals 7198 216739855    30111
7 ---
8 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- **Sum Sq (Sum of Squares / Quadratsumme)**

Gibt an, wie viel Streuung auf den jeweiligen Einflussfaktor

(frequency_z) bzw. auf die unerklärten Unterschiede (Residuals) entfällt

Lineare Regression in R

```
1 Analysis of Variance Table
2
3 Response: RT
4           Df      Sum Sq  Mean Sq F value    Pr(>F)
5 frequency_z    1  17114356 17114356   568.37 < 2.2e-16 ***
6 Residuals 7198 216739855    30111
7 ---
8 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- **Mean Sq (Mean Square / mittlere Quadratsumme)**

Die Quadratsumme geteilt durch die Freiheitsgrade; macht die erklärte und unerklärte Streuung vergleichbar

Lineare Regression in R

```
1 Analysis of Variance Table
2
3 Response: RT
4           Df      Sum Sq  Mean Sq  F value    Pr(>F)
5 frequency_z    1  17114356 17114356   568.37 < 2.2e-16 ***
6 Residuals  7198  216739855    30111
7 ---
8 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- **F value (F-Wert)**

Verhältnis der durch den Faktor erklärten Streuung zur unerklärten Streuung; je größer der F-Wert, desto stärker spricht das Ergebnis für einen tatsächlichen Effekt

Lineare Regression in R

```
1 Analysis of Variance Table
2
3 Response: RT
4           Df      Sum Sq  Mean Sq F value    Pr(>F)
5 frequency_z    1  17114356 17114356   568.37 < 2.2e-16 ***
6 Residuals  7198  216739855     30111
7 ---
8 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- **Pr(>F) (p-Wert)**

Wahrscheinlichkeit, unter der Annahme „kein Effekt“ einen mindestens so großen F-Wert zu beobachten; ein kleiner p-Wert spricht gegen diese Annahme

Lineare Regression in R

```
1 Analysis of Variance Table
2
3 Response: RT
4           Df      Sum Sq  Mean Sq F value    Pr(>F)
5 frequency z      1  17114356 17114356   568.37 < 2.2e-16 ***
6 Residuals    7198 216739855    30111
7 ---
8 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- **Residuals (Residuen)**

Der Fehler, der nicht durch die unabhängigen Variablen erklärt wird $\rightarrow \epsilon$

Lineare Regression in R

- Mit der `summary()` Funktion erfahren wir, welcher Natur ein Effekt ist

```
1 Call:
2 lm(formula = RT ~ frequency_z, data = dat)
3
4 Residuals:
5      Min       1Q   Median       3Q      Max
6 -447.76 -122.88  -23.69  101.96  912.55
7
8 Coefficients:
9             Estimate Std. Error t value Pr(>|t|)
10 (Intercept)   640.722      2.062   310.73  <2e-16 ***
11 frequency_z  -52.186      2.189   -23.84  <2e-16 ***
12 ---
13 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
14
15 Residual standard error: 173.5 on 7198 degrees of freedom
16 Multiple R-squared:  0.07318, Adjusted R-squared:  0.07306
17 F-statistic: 568.4 on 1 and 7198 DF,  p-value: < 2.2e-16
```

Lineare Regression in R

```
1 Call:
2 lm(formula = RT ~ frequency_z, data = dat)
3
4 Residuals:
5      Min       1Q   Median       3Q      Max
6 -447.76 -122.88  -23.69   101.96   912.55
7
8 Coefficients:
9              Estimate Std. Error t value Pr(>|t|)
10 (Intercept)   640.722      2.062   310.73  <2e-16 ***
11 frequency_z  -52.186      2.189   -23.84  <2e-16 ***
12 ---
13 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
14
15 Residual standard error: 173.5 on 7198 degrees of freedom
16 Multiple R-squared:  0.07318, Adjusted R-squared:  0.07306
17 F-statistic: 568.4 on 1 and 7198 DF,  p-value: < 2.2e-16
```

- **Call**

Zeigt, welches Modell gerechnet wurde: RT wird durch frequency_z vorhergesagt

Lineare Regression in R

```
1 Call:
2 lm(formula = RT ~ frequency_z, data = dat)
3
4 Residuals:
5      Min       1Q   Median       3Q      Max
6 -447.76 -122.88  -23.69  101.96  912.55
7
8 Coefficients:
9             Estimate Std. Error t value Pr(>|t|)
10 (Intercept)   640.722      2.062   310.73  <2e-16 ***
11 frequency_z  -52.186      2.189   -23.84  <2e-16 ***
12 ---
13 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
14
15 Residual standard error: 173.5 on 7198 degrees of freedom
16 Multiple R-squared:  0.07318, Adjusted R-squared:  0.07306
17 F-statistic: 568.4 on 1 and 7198 DF,  p-value: < 2.2e-16
```

- **Residuals**

Beschreibt die Verteilung der Vorhersagefehler des Modells, also die Unterschiede zwischen beobachteten und vorhergesagten RT-Werten

Lineare Regression in R

```
1 Call:
2 lm(formula = RT ~ frequency_z, data = dat)
3
4 Residuals:
5      Min       1Q   Median       3Q      Max
6 -447.76 -122.88  -23.69   101.96   912.55
7
8 Coefficients:
9             Estimate Std. Error t value Pr(>|t|)
10 (Intercept)   640.722      2.062   310.73  <2e-16 ***
11 frequency_z  -52.186      2.189   -23.84  <2e-16 ***
12 ---
13 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
14
15 Residual standard error: 173.5 on 7198 degrees of freedom
16 Multiple R-squared:  0.07318, Adjusted R-squared:  0.07306
17 F-statistic: 568.4 on 1 and 7198 DF,  p-value: < 2.2e-16
```

- **Min / 1Q / Median / 3Q / Max**

Fassen die Verteilung der Residuen zusammen; der Median sollte idealerweise ungefähr bei 0 liegen

Lineare Regression in R

```
1 Call:
2 lm(formula = RT ~ frequency_z, data = dat)
3
4 Residuals:
5      Min       1Q   Median       3Q      Max
6 -447.76 -122.88  -23.69  101.96  912.55
7
8 Coefficients:
9             Estimate Std. Error t value Pr(>|t|)
10 (Intercept)   640.722     2.062   310.73  <2e-16 ***
11 frequency_z  -52.186     2.189   -23.84  <2e-16 ***
12 ---
13 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
14
15 Residual standard error: 173.5 on 7198 degrees of freedom
16 Multiple R-squared:  0.07318, Adjusted R-squared:  0.07306
17 F-statistic: 568.4 on 1 and 7198 DF,  p-value: < 2.2e-16
```

- **Estimate**

Geschätzter Effekt eines Prädiktors auf die abhängige Variable

Lineare Regression in R

```
1 Call:
2 lm(formula = RT ~ frequency_z, data = dat)
3
4 Residuals:
5      Min       1Q   Median       3Q      Max
6 -447.76 -122.88  -23.69  101.96  912.55
7
8 Coefficients:
9      Estimate Std. Error t value Pr(>|t|)
10 (Intercept)  640.722     2.062   310.73  <2e-16 ***
11 frequency_z  -52.186     2.189   -23.84  <2e-16 ***
12 ---
13 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
14
15 Residual standard error: 173.5 on 7198 degrees of freedom
16 Multiple R-squared:  0.07318, Adjusted R-squared:  0.07306
17 F-statistic: 568.4 on 1 and 7198 DF,  p-value: < 2.2e-16
```

- **(Intercept)**

Erwartete RT bei $\text{frequency_z} = 0$; da frequency_z standardisiert ist, entspricht das einer durchschnittlichen Frequenz; hier: ca. 641 ms

Lineare Regression in R

```
1 Call:
2 lm(formula = RT ~ frequency_z, data = dat)
3
4 Residuals:
5      Min       1Q   Median       3Q      Max
6 -447.76 -122.88  -23.69   101.96   912.55
7
8 Coefficients:
9      Estimate Std. Error t value Pr(>|t|)
10 (Intercept)  640.722     2.062   310.73  <2e-16 ***
11 frequency_z  -52.186     2.189   -23.84  <2e-16 ***
12 ---
13 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
14
15 Residual standard error: 173.5 on 7198 degrees of freedom
16 Multiple R-squared:  0.07318, Adjusted R-squared:  0.07306
17 F-statistic: 568.4 on 1 and 7198 DF,  p-value: < 2.2e-16
```

- **frequency_z – Estimate**

Veränderung der vorhergesagten RT bei einer Erhöhung der Frequenz um eine Standardabweichung; hier: ca. 52 ms kürzere RT

Lineare Regression in R

```
1 Call:
2 lm(formula = RT ~ frequency_z, data = dat)
3
4 Residuals:
5      Min       1Q   Median       3Q      Max
6 -447.76 -122.88  -23.69   101.96   912.55
7
8 Coefficients:
9             Estimate Std. Error t value Pr(>|t|)
10 (Intercept)   640.722     2.062   310.73  <2e-16 ***
11 frequency_z  -52.186     2.189   -23.84  <2e-16 ***
12 ---
13 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
14
15 Residual standard error: 173.5 on 7198 degrees of freedom
16 Multiple R-squared:  0.07318, Adjusted R-squared:  0.07306
17 F-statistic: 568.4 on 1 and 7198 DF,  p-value: < 2.2e-16
```

- **Std. Error**

Unsicherheit der jeweiligen Effektschätzung; kleinere Werte bedeuten eine präzisere Schätzung

Lineare Regression in R

```
1 Call:
2 lm(formula = RT ~ frequency_z, data = dat)
3
4 Residuals:
5      Min       1Q   Median       3Q      Max
6 -447.76 -122.88  -23.69  101.96  912.55
7
8 Coefficients:
9             Estimate Std. Error t value Pr(>|t|)
10 (Intercept)   640.722      2.062   310.73  <2e-16 ***
11 frequency_z  -52.186      2.189  -23.84  <2e-16 ***
12 ---
13 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
14
15 Residual standard error: 173.5 on 7198 degrees of freedom
16 Multiple R-squared:  0.07318, Adjusted R-squared:  0.07306
17 F-statistic: 568.4 on 1 and 7198 DF,  p-value: < 2.2e-16
```

- **t value**

Ergebnis des t-Tests für den jeweiligen Koeffizienten; berechnet als
Estimate / Std. Error

Lineare Regression in R

```
1 Call:
2 lm(formula = RT ~ frequency_z, data = dat)
3
4 Residuals:
5      Min       1Q   Median       3Q      Max
6 -447.76 -122.88  -23.69  101.96  912.55
7
8 Coefficients:
9              Estimate Std. Error t value Pr(>|t|)
10 (Intercept)   640.722      2.062   310.73  <2e-16 ***
11 frequency_z  -52.186      2.189   -23.84  <2e-16 ***
12 ---
13 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
14
15 Residual standard error: 173.5 on 7198 degrees of freedom
16 Multiple R-squared:  0.07318, Adjusted R-squared:  0.07306
17 F-statistic: 568.4 on 1 and 7198 DF,  p-value: < 2.2e-16
```

- **Pr(>|t|): p-Wert des t-Tests**

Gibt an, wie wahrscheinlich ein mindestens so großer t-Wert wäre, wenn der tatsächliche Koeffizient 0 wäre

Lineare Regression in R

```
1 Call:
2 lm(formula = RT ~ frequency_z, data = dat)
3
4 Residuals:
5      Min       1Q   Median       3Q      Max
6 -447.76 -122.88  -23.69  101.96  912.55
7
8 Coefficients:
9             Estimate Std. Error t value Pr(>|t|)
10 (Intercept)   640.722      2.062   310.73  <2e-16 ***
11 frequency_z  -52.186      2.189   -23.84  <2e-16 ***
12 ---
13 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
14
15 Residual standard error: 173.5 on 7198 degrees of freedom
16 Multiple R-squared:  0.07318, Adjusted R-squared:  0.07306
17 F-statistic: 568.4 on 1 and 7198 DF,  p-value: < 2.2e-16
```

- **Residual standard error**

Typische Größe der verbleibenden Vorhersagefehler des Modells; hier liegen beobachtete RTs etwa 174 ms von den Modellvorhersagen entfernt

Lineare Regression in R

```
1 Call:
2 lm(formula = RT ~ frequency_z, data = dat)
3
4 Residuals:
5      Min       1Q   Median       3Q      Max
6 -447.76 -122.88  -23.69  101.96  912.55
7
8 Coefficients:
9             Estimate Std. Error t value Pr(>|t|)
10 (Intercept)   640.722     2.062   310.73  <2e-16 ***
11 frequency_z  -52.186     2.189   -23.84  <2e-16 ***
12 ---
13 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
14
15 Residual standard error: 173.5 on 7198 degrees of freedom
16 Multiple R-squared:  0.07318, Adjusted R-squared:  0.07306
17 F-statistic: 568.4 on 1 and 7198 DF,  p-value: < 2.2e-16
```

- **Degrees of freedom**

Freiheitsgrade, die zur Schätzung der verbleibenden Fehlervarianz zur Verfügung stehen

Lineare Regression in R

```
1 Call:
2 lm(formula = RT ~ frequency_z, data = dat)
3
4 Residuals:
5      Min       1Q   Median       3Q      Max
6 -447.76 -122.88  -23.69  101.96  912.55
7
8 Coefficients:
9             Estimate Std. Error t value Pr(>|t|)
10 (Intercept)   640.722      2.062   310.73  <2e-16 ***
11 frequency_z  -52.186      2.189   -23.84  <2e-16 ***
12 ---
13 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
14
15 Residual standard error: 173.5 on 7198 degrees of freedom
16 Multiple R-squared:  0.07318, Adjusted R-squared:  0.07306
17 F-statistic: 568.4 on 1 and 7198 DF,  p-value: < 2.2e-16
```

- **Multiple R-squared**

Anteil der Varianz in RT, den das Modell erklärt; hier etwa 7,3 %

Lineare Regression in R

```
1 Call:
2 lm(formula = RT ~ frequency_z, data = dat)
3
4 Residuals:
5      Min       1Q   Median       3Q      Max
6 -447.76 -122.88  -23.69  101.96  912.55
7
8 Coefficients:
9              Estimate Std. Error t value Pr(>|t|)
10 (Intercept)   640.722     2.062   310.73  <2e-16 ***
11 frequency_z  -52.186     2.189   -23.84  <2e-16 ***
12 ---
13 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
14
15 Residual standard error: 173.5 on 7198 degrees of freedom
16 Multiple R-squared:  0.07318, Adjusted R-squared:  0.07306
17 F-statistic: 568.4 on 1 and 7198 DF,  p-value: < 2.2e-16
```

- **Adjusted R-squared**

Um die Anzahl der Prädiktoren korrigiertes R^2 ; bei nur einem Prädiktor ist es fast identisch mit dem normalen R^2

Lineare Regression in R

```
1 Call:
2 lm(formula = RT ~ frequency_z, data = dat)
3
4 Residuals:
5      Min       1Q   Median       3Q      Max
6 -447.76 -122.88  -23.69  101.96  912.55
7
8 Coefficients:
9             Estimate Std. Error t value Pr(>|t|)
10 (Intercept)   640.722      2.062   310.73  <2e-16 ***
11 frequency_z  -52.186      2.189   -23.84  <2e-16 ***
12 ---
13 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
14
15 Residual standard error: 173.5 on 7198 degrees of freedom
16 Multiple R-squared:  0.07318, Adjusted R-squared:  0.07306
17 F-statistic: 568.4 on 1 and 7198 DF,  p-value: < 2.2e-16
```

- **F-statistic**

Ergebnis des F-Tests für das Gesamtmodell; prüft, ob das Modell mit frequency_z besser erklärt als ein Modell ohne Prädiktor

Lineare Regression in R

```
1 Call:
2 lm(formula = RT ~ frequency_z, data = dat)
3
4 Residuals:
5      Min       1Q   Median       3Q      Max
6 -447.76 -122.88  -23.69  101.96  912.55
7
8 Coefficients:
9             Estimate Std. Error t value Pr(>|t|)
10 (Intercept)   640.722      2.062   310.73  <2e-16 ***
11 frequency_z  -52.186      2.189   -23.84  <2e-16 ***
12 ---
13 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
14
15 Residual standard error: 173.5 on 7198 degrees of freedom
16 Multiple R-squared:  0.07318, Adjusted R-squared:  0.07306
17 F-statistic: 568.4 on 1 and 7198 DF, p-value: < 2.2e-16
```

- **p-value beim F-Test**


p-Wert des Gesamtmodelltests; hier $p < .001$, das Modell mit Frequenz erklärt also signifikant mehr Varianz als das Nullmodell

Lineare Regression: Annahmen

- Laut unserem Modell sinkt die Reaktionszeit signifikant, wenn die Frequenz ansteigt
- Allerdings wissen wir gar nicht, ob unser Modell zuverlässig ist – wir haben nicht überprüft, ob es den Annahmen linearer Regression folgt:
 - **Linearität / Linearity**
 - **Homoskedastizität / Homoscedasticity**
 - **Normalität / Normality**
 - **Unabhängigkeit / Independence**

Annahme: Linearität

Der Zusammenhang zwischen Prädiktor und abhängiger Variable wird durch eine lineare Beziehung angemessen beschrieben




- Es sollte kein systematisches Muster oder keine Krümmung erkennbar sein

Annahme: Homoskedastizität

Die Varianz der Residuen ist über den gesamten Wertebereich der vorhergesagten Werte ungefähr konstant

Homogeneity of Variance
Reference line should be flat and horizontal




- Residuen sollten über den gesamten Wertebereich ungefähr gleich streuen

Annahme: Normalität

Die Residuen des Modells sind annähernd normalverteilt

Normality of Residuals
Dots should fall along the line



- Die Punkte sollten ungefähr entlang der Referenzlinie liegen

Annahme: Unabhängigkeit

Die einzelnen Beobachtungen bzw. Residuen beeinflussen einander
nicht systematisch


- Über das Design: Sind die einzelnen Beobachtungen tatsächlich unabhängig voneinander?
- Bei geordneten Daten (z. B. Zeitreihen, Trial-Reihenfolge) kann man Autokorrelation der Residuen prüfen, etwa mit einem Durbin-Watson-Test

Extra: Outlier

Beobachtungen, die ungewöhnlich stark vom Modell abweichen oder einen besonders großen Einfluss auf die geschätzten Modellparameter haben

Influential Observations

Points should be inside the contour lines



Merke

Ein Ausreißer ist nicht automatisch ein Fehler und sollte nicht automatisch gelöscht werden

Überprüfung der Verteilung

- Vielen Problemen mit Modellannahmen kann man aus dem Weg gehen, wenn die **abhängige Variable** (annähernd) **normalverteilt** ist
- Daher sollte man vor dem Erstellen von Modellen überprüfen, ob die abhängige Variable diese Voraussetzung erfüllt
- Falls die Verteilung fernab einer Normalverteilung liegt, ist es ratsam die Variable zu **transformieren**

Überprüfung der Verteilung

- Man kann die Verteilung einer Variable mit einem **Shapiro-Wilk Test** überprüfen
- Je höher der p-Wert, desto normaler verteilt ist die Variable
= je kleiner, desto weniger normalverteilt


```
1      Shapiro-Wilk normality test
2
3 data:  dat$RT
4 W = 0.97203, p-value < 2.2e-16
```

⚠ Bei großen Stichproben werden auch sehr kleine Abweichungen von der Normalverteilung signifikant; deshalb sollte die Verteilung zusätzlich bzw. eher grafisch, z. B. mit einem Q-Q-Plot, beurteilt werden + der Befehl kann nur max. 5000 Datenpunkte händeln

Überprüfung der Verteilung

- Q-Q-Plot


Selbes Prinzip wie bei der Prüfung der Normalität, d.h. die Punkte sollten ungefähr entlang der Referenzlinie liegen




Überprüfung der Verteilung

- Q-Q-Plot

Selbes Prinzip wie bei der Prüfung der Normalität, d.h. die Punkte sollten ungefähr entlang der Referenzlinie liegen



RT



log_RT

Wie log-transformiert man eine Variable?

- Das ist simpel

```
1 dat$log_RT <- log(RT)
2
3 shapiro.test(dat$log_RT)
4
5 Shapiro-Wilk normality test
6
7 data:  dat$log_RT
8 W = 0.99909, p-value = 0.009267
```

- Die Verteilung ist jetzt (erwartbarerweise) nicht perfekt normalverteilt - wir haben ja bereits die kleinen Ausreißer im Q-Q-Plot gesehen - jedoch doch eindeutig normalverteilter als zuvor

Wie log-transformiert man eine Variable?

- Eine Visualisierung zeigt deutlich, dass die transformierte Variable normalverteilter ist

