

Multiple Regression & Kontrollvariablen

GRK2700 Statistik-Workshop
am 24. August 2026

Dr. Dominic Schmitz
dominic.schmitz@hhu.de

Lineare Regression: Formel


$$Y = \beta_0 + \beta_1 X + \epsilon$$



Wie verändert sich die Reaktionszeit in Abhängigkeit von der Wortfrequenz?

$$RT = \beta_0 + \beta_1 \text{Frequenz} + \epsilon$$

(Zu) einfache lineare Regression



Einfache lineare Regression: Formel

kontinuierliche
abhängige Variable

unabhängige
Prädiktorvariable

$$Y = \beta_0 + \beta_1 X + \epsilon$$

Steigung/
Slope

Residuen/
Error Term

y-Achsenabschnitt/
Intercept

Multiple lineare Regression: Formel

kontinuierliche abhängige Variable

unabhängige Prädiktorvariable 1

unabhängige Prädiktorvariable 2

unabhängige Prädiktorvariable i

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_i X_i + \epsilon$$

y-Achsenabschnitt

Steigung von Variable 1

Steigung von Variable 2

Steigung von Variable i

Residuen/ Error Term

The diagram shows the multiple linear regression formula $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_i X_i + \epsilon$ enclosed in a light blue box. Arrows point from descriptive labels to each term in the formula: Y is labeled 'kontinuierliche abhängige Variable'; β_0 is 'y-Achsenabschnitt'; $\beta_1 X_1$ is labeled with 'unabhängige Prädiktorvariable 1' (pointing to X_1) and 'Steigung von Variable 1' (pointing to β_1); $\beta_2 X_2$ is labeled with 'unabhängige Prädiktorvariable 2' (pointing to X_2) and 'Steigung von Variable 2' (pointing to β_2); $\beta_i X_i$ is labeled with 'unabhängige Prädiktorvariable i' (pointing to X_i) and 'Steigung von Variable i' (pointing to β_i); and ϵ is labeled 'Residuen/ Error Term'.

Multiple Regression ist keine völlig neue Methode; wir erlauben unserem linearen Modell lediglich mehrere Prädiktoren

Multiple lineare Regression

- Der Koeffizient beschreibt den Zusammenhang zwischen Wortfrequenz und RT

```
1 mdl_einfache <- lm(RT ~ frequency_z, dat)
```

- Jeder Koeffizient beschreibt den Effekt eines Prädiktors, während die übrigen Prädiktoren im Modell konstant gehalten = kontrolliert werden

```
1 mdl_multiple <- lm(RT ~ frequency_z + condition + length, dat)
```

Kontrollvariable

- eine Variable, die nicht primär Gegenstand der Forschungsfrage ist, aber in das Modell aufgenommen wird, weil sie mit der abhängigen Variable und/oder dem interessierenden Prädiktor zusammenhängen kann
- „Kontrollvariable“ ist dabei keine besondere statistische Variablenart; sie einfach ein weiterer Prädiktor im Regressionsmodell

```
1 mdl_multiple <- lm(RT ~ frequency_z + condition + length dat)
```

Hauptvariable

Kontrollvariablen

- Für `lm()` ist die Unterscheidung völlig irrelevant; sie erwächst aus der Forschungsfrage

Woher kommen Kontrollvariablen?

- „Alles kontrollieren, was verfügbar ist.“
→ weder praktisch machbar noch statistisch umsetzbar
 - Stattdessen erfolgt die Auswahl typischerweise aufgrund von
 - Theorie und früherer Forschung
 - bekannten Einflussfaktoren auf die abhängige Variable
 - Studiendesign
 - plausiblen Confounds
- ⚠ Eine Variable sollte nicht allein deshalb kontrolliert werden, weil sie im Datensatz vorhanden ist

Was bedeutet „kontrollieren“ eigentlich?

```
1 mdl_multiple <- lm(RT ~ frequency_z + condition + length, dat)
```

- Wir schätzen den Zusammenhang zwischen Frequenz und RT bei gleichem Wert von `condition` und `length`
- Kontrollieren bedeutet nicht, dass
 - wir `condition` und `length` aus den Daten „entfernen“
 - der Einfluss von `condition` und `length` vollständig verschwindet
 - wir Versuchspersonen mit exakt gleichen Werten vergleichen
- „Wie hängt Frequenz mit RT zusammen, wenn `condition` und `length` statistisch konstant gehalten werden?“

Was müssen Kontrollvariablen erfüllen?

- DER Mythos: Müssen Kontrollvariablen normalverteilt sein?
→ NEIN, die Normalitätsannahme der linearen Regression betrifft nicht die Verteilung der Prädiktoren

Muss eine Kontrollvariable ...	
normalverteilt sein?	nein
kontinuierlich sein?	nein
signifikant sein?	nein
mit der abhängigen Variable korrelieren?	nicht zwingend
theoretisch begründet sein?	idealerweise ja

...signifikant sein?

- Nehmen wir an, unser Modell zeigt folgende Werte

1		Df	Sum Sq	Mean Sq	F value	Pr(>F)	
2	frequency_z	1	17114356	17114356	574.1472	<2e-16	***
3	condition	1	2239292	2239292	75.1231	<2e-16	***
4	length_fake	1					
			3	3	0.0001	0.9916	

- Dann ist die falsche Schlussfolgerung:
„Länge ist nicht signifikant, also nehme ich die Variable heraus“
- Wenn `length` aus theoretischen Gründen aufgenommen wurde, kann sie im Modell bleiben, unabhängig davon, ob ihr eigener Koeffizient signifikant ist
- Der Zweck ist die Schätzung der Hauptvariable unter Berücksichtigung von `length`, NICHT das Belegen eines Effekts von `length` selbst

...mit der AV zusammenhängen/korrelieren?

- Eine Variable, die weder mit der AV noch mit dem interessierenden Prädiktor in irgendeiner relevanten Weise zusammenhängt, bringt typischerweise wenig



Merke

Kontrollvariablen werden a priori aufgrund theoretischer oder designbezogener Überlegungen gewählt, nicht aufgrund eines vorgelagerten Signifikanztests

„Mehr kontrollieren = besser“?

- Nein.
 - In Papers klingt es häufig so, als sei mehr Kontrolle automatisch wissenschaftlich rigoroser
- ⚠ Jede zusätzliche Kontrollvariable verändert die Frage, die das Modell beantwortet
- Kontrollvariablen sind keine kostenlose/konsequenzlose statistische Verbesserung

Kann man die „falsche“ Variable kontrollieren?

- Ja.
- Wenn eine Variable bspw. Folge des interessierenden Prädiktors ist, kann ihre Kontrolle einen Teil des eigentlich interessierenden Effekts entfernen
- Wenn wir wissen wollen, welchen gesamten Effekt X auf Y hat, und dann für Z kontrollieren, beantworten wir plötzlich eine andere Frage

$$X \rightarrow Z \rightarrow Y$$

- „Nimm einfach alles mit, dann bist du auf der sicheren Seite“ ist eben manchmal nicht zutreffend

Kontrollvariable vs. Confound

- Nicht jede Kontrollvariable ist automatisch ein Confound

- **Confound**

Eine Variable, die eine alternative Erklärung für den beobachteten Zusammenhang zwischen X und Y darstellen kann

- **Kontrollvariable**

Allgemeinerer Begriff für eine Variable, die zusätzlich ins Modell aufgenommen wird

- Aber: In vielen Papers werden diese Begriffe recht locker verwendet

Was sollte man tatsächlich prüfen?

- Die Normalitätsannahme der linearen Regression betrifft nicht die Verteilung der Prädiktoren
- Aber: die funktionale Form des Zusammenhangs einer Variable X mit Y muss angemessen modelliert sein
- Und Skalierung/Zentrierung? Zentrieren oder z-Standardisieren kann praktisch sein, insbesondere
 - zur leichteren Interpretation des Intercepts
 - bei sehr unterschiedlichen Skalen
 - später bei Interaktionen
- Aber: Standardisieren ist keine Voraussetzung für multiple Regression

Was müssen Kontrollvariablen erfüllen?

Muss eine Kontrollvariable ...	
normalverteilt sein?	nein
kontinuierlich sein?	nein
significant sein?	nein
mit der abhängigen Variable korrelieren?	nicht zwingend
theoretisch begründet sein?	idealerweise ja

Was ist Modellspezifikation?

- **Modellspezifikation**

Entscheidung darüber, welche Prädiktoren in welcher Form in das Modell aufgenommen werden

```
1 mdl_einfache <- lm(RT ~ frequency_z, dat)
```

```
1 mdl_doppelte <- lm(RT ~ frequency_z + condition, dat)
```

```
1 mdl_multiple <- lm(RT ~ frequency_z + condition + length, dat)
```

Welche Variable interessiert uns eigentlich?

- Forschungsfrage

Wie hängt Wortfrequenz mit Reaktionszeiten in einer Lexical-Decision-Aufgabe zusammen?

- Demnach: Variable of interest = `frequency`
- Zusätzliche Variablen könnten z. B. aus Theorie, früherer Forschung oder dem Studiendesign kommen



Merke

Wir beginnen nicht mit den Variablen im Datensatz, sondern mit der Forschungsfrage

Was ist Modellspezifikation?

- Diese Modelle unterscheiden sich nicht nur in ihrer Komplexität; sie beantworten unterschiedliche Fragen

```
1 mdl_einfache <- lm(RT ~ frequency_z, dat)
```

```
1 mdl_doppelte <- lm(RT ~ frequency_z + condition, dat)
```

```
1 mdl_multiple <- lm(RT ~ frequency_z + condition + length, dat)
```

- Wie hängt Frequenz mit RT zusammen?
- Wie hängt Frequenz mit RT zusammen, wenn Wortlänge konstant gehalten wird?
- Wie hängt Frequenz mit RT zusammen, wenn Wortlänge und Trial Number konstant gehalten werden?

Gründe, einen Prädiktor aufzunehmen

- Ein Prädiktor kann ins Modell kommen, weil er...
 - direkt Teil der Forschungsfrage ist
 - theoretisch relevant ist
 - als Kontrollvariable benötigt wird
 - aus dem Studiendesign resultiert
 - für einen gezielten Modellvergleich benötigt wird
- Noch einmal: Keine guten Gründe sind...
 - die Variable ist im Datensatz
 - vielleicht wird sie ja signifikant

Muss ein Modell immer reduziert werden?

- Womöglich kennt ihr (step-wise) Reduktion von Regressionsmodellen aus Papers
- Wichtig: Es gibt keinen „Zwang“ zur generellen Modell-Reduktion; es ist eher eine Tradition
- Wenn man ein theoretisch begründetes Modell hat, das Variablen ohne Effekt umfasst, gibt es keinen allgemeingültigen Grund, solche Variablen zu entfernen
- „Finales Modell“ bedeutet nicht automatisch „kleinstes Modell mit ausschließlich signifikanten Prädiktoren“

Wann kann Modellvergleich sinnvoll sein?

- Angenommen, es gibt zwei inhaltlich plausible Modelle

```
1 mdl_einfache <- lm(RT ~ frequency_z, dat)
```

```
1 mdl_doppelte <- lm(RT ~ frequency_z + trial_number, dat)
```

- Liefert `trial_number` zusätzliche Erklärung, nachdem `frequency` bereits berücksichtigt wurden? Das kann ein Modellvergleich beantworten



Merke

Wir vergleichen nicht wahllos alle denkbaren Kombinationen, sondern konkrete, begründete Modelle

Nested models / verschachtelte Modelle

- Ein Modell ist im anderen enthalten

```
1 mdl_einfache <- lm(RT ~ frequency_z, dat)
```

```
1 mdl_doppelte <- lm(RT ~ frequency_z + trial_number, dat)
```

- `mdl_einfache` ist ein Spezialfall von `mdl_doppelte`, weil `mdl_doppelte` lediglich einen zusätzlichen Prädiktor enthält; dann

```
1 > anova(mdl_einfache, mdl_doppelte)
2 Analysis of Variance Table
3
4 Model 1: RT ~ frequency_z
5 Model 2: RT ~ frequency_z + trial_z
6   Res.Df      RSS Df Sum of Sq    F  Pr(>F)
7 1     7198 216739855
8 2     7197 216613832  1    126023 4.1871 0.04077 *
```

- Reicht die zusätzliche erklärte Varianz aus, um den zusätzlichen Prädiktor zu rechtfertigen?

Nested models / verschachtelte Modelle

```
1 > anova(mdl_einfache, mdl_doppelte)
2 Analysis of Variance Table
3
4 Model 1: RT ~ frequency_z
5 Model 2: RT ~ frequency_z + trial_z
6   Res.Df      RSS Df Sum of Sq      F    Pr(>F)
7 1      7198 216739855
8 2      7197 216613832  1    126023 4.1871 0.04077 *
```

- Wenn der Vergleich signifikant ist: Das komplexere Modell beschreibt die Daten besser als das einfachere Modell
- Wenn der Vergleich nicht signifikant ist: Nicht genügend Evidenz dafür, dass der zusätzliche Prädiktor die Modellanpassung verbessert
- Aber: Das bedeutet nicht automatisch, dass der Prädiktor entfernt werden muss

Nested models / verschachtelte Modelle

```
1 > AIC mdl_einfache, mdl_doppelte)
2           df          AIC
3 mdl_einfache    3 94687.79
4 mdl_doppelte    4 94685.61
```

- Der **AIC** bewertet den Trade-off zwischen Modellanpassung und Modellkomplexität
- Niedrigerer AIC = unter den verglichenen Modellen bevorzugt
- Ab einem Unterschied von 2 AIC-Punkten geht man i.d.R. von einem relevanten Unterschied zwischen den Modellen aus; hier $\Delta 2.18$

Die `step()` Funktion

- Kann R das „beste“ Modell für uns finden?
 - Ja, R kann automatisiert Prädiktoren hinzufügen oder entfernen
- Aber: Das ist nicht automatisch die beste wissenschaftliche Strategie, denn
 - Ergebnisse hängen vom Auswahlkriterium und Startmodell ab
 - theoretisch wichtige Variablen können entfernt werden
 - die Selektion erfolgt datengetrieben
 - nachträgliche p-Werte werden leicht zu optimistisch interpretiert
- Wichtig: `step()` ersetzt keine theoretische Modellspezifikation

Hypothesengeleitete vs. explorative Statistik


- **Hypothesengeleitete Analyse**

- Prädiktoren werden vorher begründet
- Das Modell folgt der Forschungsfrage
- Nicht-signifikante Variablen müssen nicht automatisch entfernt werden

- **Explorative Analyse**

- Verschiedene Modelle oder Prädiktoren werden untersucht
- Modellselektion kann Bestandteil der Analyse sein
- Muss transparent als explorativ berichtet werden

Wege zum finalen Modell



Trägt ein Prädiktor zur Erklärung von RT bei?

```
1 > anova(mdl_multiple)
2           Df      Sum Sq  Mean Sq F value    Pr(>F)
3 frequency    1  17114356 17114356  591.932 < 2.2e-16 ***
4 condition    3   7695212   2565071   88.718 < 2.2e-16 ***
5 length       1   1046562   1046562   36.197 1.871e-09 ***
```

- Kennen wir schon
 - Df (Degrees of Freedom / Freiheitsgrade)
 - Sum Sq (Sum of Squares / Quadratsumme)
 - Mean Sq (Mean Square / mittlere Quadratsumme)
 - F value (F-Wert)
 - Pr(>F) (p-Wert)

Trägt ein Prädiktor zur Erklärung von RT bei?

```
1 > anova(mdl_multiple)
2           Df      Sum Sq  Mean Sq F value    Pr(>F)
3 frequency    1  17114356 17114356  591.932 < 2.2e-16 ***
4 condition    3   7695212   2565071   88.718 < 2.2e-16 ***
5 length       1   1046562   1046562   36.197 1.871e-09 ***
```

- Neu: Die Freiheitsgrade bei `condition` sind höher als 1
→ kategorialer Prädiktor mit 4 Stufen = 4-1 Freiheitsgrade
 - Der p-Wert hier testet, ob es insgesamt Evidenz dafür gibt, dass sich mindestens zwei der Bedingungen voneinander unterscheiden
→ der p-Wert sagt uns nicht, welche Bedingungen sich unterscheiden
- ⚠ Die Reihenfolge der Prädiktoren in der Modellformel kann das Ergebnis beeinflussen
→ Warum das so ist, besprechen wir morgen

Welcher Natur ist ein geschätzter Effekt?

	Estimate	Std. Error	t value	Pr(> t)
1				
2	(Intercept)			
3	frequency			
4	conditionb			
5	conditionc			
6	conditiond			
7	length			

- Kennen wir schon
 - Estimate = geschätzter Koeffizient
 - Std. Error = Unsicherheit der Schätzung
 - t value = Estimate / Standard Error
 - p-Wert = Evidenz gegen H0
- Aber wie interpretiert man die Estimates, wenn man mehr als eine unabhängige Variable im Modell hat?

Welcher Natur ist ein geschätzter Effekt?

1		Estimate	Std. Error	t value	Pr(> t)
2	(Intercept)	554.801			
3	frequency	-43.572			
4	conditionb	-14.113			
5	conditionc	63.366			
6	conditiond	-11.525			
7	length	12.692			

- **Kontinuierliche Prädiktoren**

- Wenn `frequency` um eine Einheit steigt, sinkt die vorhergesagte RT um 43.6 ms bei konstanten Werten aller anderen Prädiktoren im Modell
- Wenn `length` um eine Einheit steigt, steigt die vorhergesagte RT um 12.7 ms bei konstanten Werten aller anderen Prädiktoren im Modell

Welcher Natur ist ein geschätzter Effekt?

1		Estimate	Std. Error	t value	Pr(> t)
2	(Intercept)	554.801			
3	frequency	-43.572			
4	conditionb	-14.113			
5	conditionc	63.366			
6	conditiond	-11.525			
7	length	12.692			

- Intercept
 - Die vorhergesagte RT bei `frequency = 0` und `length = 0` und `condition = a`
 - Ist das überhaupt ein sinnvoller Zustand? Wohl eher nicht
 - Sind die involvierten kontinuierlichen Variablen alle zentriert, dann ist der Intercept die vorhergesagte RT für ein Wort mit durchschnittlicher Frequenz und durchschnittlicher Länge in Bedingung a
→ sinnvoller & verständlicher!

Welcher Natur ist ein geschätzter Effekt?

1		Estimate	Std. Error	t value	Pr(> t)
2	(Intercept)	554.801			
3	frequency	-43.572			
4	conditionb	-14.113			
5	conditionc	63.366			
6	conditiond	-11.525			
7	length	12.692			

- **Kategoriale Prädiktoren**

- Bei Standardeinstellungen verwendet R das alphabetisch erste Level eines kategorialen Prädiktors als Bestandteil des Intercepts
- Entsprechend werden die Kontraste zu diesem in der Tabelle aufgeführt

Welcher Natur ist ein geschätzter Effekt?

1		Estimate	Std. Error	t value	Pr(> t)
2	(Intercept)	554.801			
3	frequency	-43.572			
4	conditionb	-14.113			
5	conditionc	63.366			
6	conditiond	-11.525			
7	length	12.692			

- Intercept & kategoriale Prädiktoren

- Interessiert uns aber `condition = b`, so müssen wir rechnen

$$554.801 - 14.113 = 540.688$$

- Interessiert uns `condition = c`, so müssen wir rechnen

$$554.801 + 63.366 = 618.167$$

- Damit hat `condition = d` keine RT von -11.5 ms sondern zeigt einen Unterschied zu `condition = a` von 11.5 ms *all else being equal*

Welcher Natur ist ein geschätzter Effekt?

1		Estimate	Std. Error	t value	Pr(> t)	
2	(Intercept)	554.801				
3	frequency	-43.572				
4	conditionb	-14.113	5.689	-2.481	0.0131	*
5	conditionc	63.366	5.668	11.179	< 2e-16	***
6	conditiond	-11.525	5.711	-2.018	0.0436	*
7	length	12.692				

- Kategoriale Prädiktoren & p-Werte
 - Wir wissen a vs. b = 0.0131 & a vs. c < 2e-16 & a vs. d = 0.0436
 - Aber was ist, wenn wir bspw. b vs. c wissen möchten?

Post-hoc-Vergleiche

- Für systematische Vergleiche zwischen Faktorstufen nutzen wir

Post-hoc-Vergleiche

```
1 > pairs(emmeans mdl_multiple, ~ condition)
2 contrast estimate SE df t.ratio p.value
3 a - b 14.11 5.69 7194 2.481 0.0630
4 a - c -63.37 5.67 7194 -11.179 <.0001
5 a - d 11.53 5.71 7194 2.018 0.1813
6 b - c -77.48 5.69 7194 -13.626 <.0001
7 b - d -2.59 5.67 7194 -0.456 0.9684
8 c - d 74.89 5.71 7194 13.126 <.0001
```

- Unter Berücksichtigung aller anderen Variablen berechnet dieser Befehl modellbasierte, adjustierte Mittelwerte und darauf basierende p-Werte für alle Vergleiche einer kategorialen Variable

Das Problem von Post-hoc-Vergleichen

- Bei einem Signifikanztest prüfen wir typischerweise, ob es Evidenz für die H_0 gibt
- Wenn wir H_0 verwerfen, obwohl sie in Wahrheit korrekt ist, begehen wir einen s.g. **Fehler 1. Art** / **Type I Error** / haben ein falsch positives Ergebnis
- Das Gegenstück wäre ein **Fehler 2. Art**: Ein tatsächlich vorhandener Effekt wird nicht entdeckt
- Wenn wir viele Tests durchführen, steigt die Wahrscheinlichkeit, irgendwo ein falsch positives Ergebnis zu erhalten

$1 - (1 - \alpha)^k$ bei 3 Tests: $1 - (1 - 0.05)^3 = 0.143$, d.h. 14 % statt 5 %

bei 6 Tests: $1 - (1 - 0.05)^6 = 0.26$, d.h. 26 % statt 5 %

Post-hoc-Vergleiche: Bonferroni-Korrektur

- Die **Bonferroni-Korrektur** hält das gesamte Fehlerrisiko der Testfamilie unter Kontrolle; bei 6 Vergleichen

$$\alpha_{\text{adjusted}} = \frac{0.05}{6} = 0.0083$$

- Man kann bei multiplen Tests also entweder
 - das Signifikanzniveau anpassen oder
 - die p-Werte entsprechend korrigieren

Post-hoc-Vergleiche: Bonferroni-Korrektur

- Die Korrektur der p-Werte ist in R sehr simpel

```
1 > pairs(emmeans mdl_multiple, ~ condition2), adjust="bonferroni")
2 contrast estimate SE df t.ratio p.value
3 a - b 14.11 5.69 7194 2.481 0.0788
4 a - c -63.37 5.67 7194 -11.179 <.0001
5 a - d 11.53 5.71 7194 2.018 0.2617
6 b - c -77.48 5.69 7194 -13.626 <.0001
7 b - d -2.59 5.67 7194 -0.456 1.0000
8 c - d 74.89 5.71 7194 13.126 <.0001
```

- Bonferroni ist als Korrektur einfach, transparent, allgemein anwendbar, konservativ
- Andere Korrekturen existieren, z. B. Holm, Tukey
- Wir verwenden Bonferroni als leicht verständliches, etabliertes Verfahren zur Kontrolle multipler Tests