

Logistische Regression

GRK2700 Statistik-Workshop
am 24. August 2026

Dr. Dominic Schmitz
dominic.schmitz@hhu.de

Ausgangspunkt: Was kennen wir bereits?

- Bisher: kontinuierliche abhängige Variable

```
1 mdl_einfache <- lm(RT ~ frequency_z + condition, dat)
```


- Aber was machen wir, wenn uns zum Beispiel interessiert, ob es Wort richtig oder falsch erkannt wurde?

accuracy: 0 = falsch, 1 = richtig

```
1 accuracy ~ frequency_z + condition
```

Warum nicht einfach lineare Regression?

- Zwei zentrale Probleme
 1. vorhergesagte Werte können <0 oder >1 werden
 2. Residuen können nicht normalverteilt sein
- Wir brauchen ein Modell, dessen Vorhersagen zwischen 0 und 1 bleiben



Wahrscheinlichkeit

- Beispiel

Von 100 Wörtern werden 80 korrekt erkannt

$$P\left(Y = \frac{\text{n günstige Fälle}}{\text{n aller Fälle}}\right)$$

$$P\left(Y = \frac{80}{100}\right)$$

→ **Wahrscheinlichkeit** einer korrekten Antwort: $p = .80$

Odds

$$\text{Odds} = \frac{p}{1 - p}$$

- bei $p = .80$

$$\text{Odds} = \frac{.80}{1 - .80} = \frac{.80}{.20} = 4$$

- Damit stehen die **Chancen** 4:1

Wahrscheinlichkeit	Odds
0.20	0.25
0.50	1
0.90	9

Log-Odds / Logit

- Warum brauchen wir **Logits**?
- Wahrscheinlichkeiten sind auf 0-1 beschränkt, das lässt sich anhand linearer Regression nicht gut abbilden
- Daher

$$\text{logit}(p) = \log\left(\frac{p}{1-p}\right)$$

- Log-Odds (=Logits) reichen von $-\infty$ bis $+\infty$, was wiederum eine lineare Gleichung ermöglicht


$$\text{logit}(.80) = \log\left(\frac{.80}{1-.80}\right) = 1.386294$$

Log-Odds / Logit

- Logit = 0 $\rightarrow p = .50$
- positive Log-Odds $\rightarrow p > .50$
- negative Log-Odds $\rightarrow p < .50$



- Eine lineare Veränderung der Log-Odds bedeutet keine lineare Veränderung der Wahrscheinlichkeit
- Die Prädiktoren wirken linear auf die Log-Odds, nicht direkt auf die Wahrscheinlichkeit



Logistische Regression in R

- Die Modellerstellung in R läuft analog zu dem, was wir schon kennen

```
1 m1 <- glm(accuracy ~ frequency_z + condition,  
2           data = dat,  
3           family = binomial)
```

- Neue Dinge
 - `glm` = Funktion für Generalized Linear Models
 - `family = binomial` = für AV mit Binomialverteilung
- Binomialverteilung ist die Verteilung, die entsteht, wenn ein Experiment mit 2 möglichen Ausgängen n -mal wiederholt wird
→ in unserem Fall: das richtige/falsche Erkennen von Wörtern

Interpretation

1		Estimate	Std. Error	z value	Pr(> z)	
2	(Intercept)	2.47359	0.06296	39.288	<2e-16	***
3	frequency_z	0.40610	0.04787	8.483	<2e-16	***
4	conditionrelated	0.25847	0.08956	2.886	0.0039	**

- Viele Dinge sind uns bereits bekannt: Estimate, Std. Error, p-Wert, Intercept, Referenzkategorie, Effekte
- Neu sind
 - z statt t Wert
 - die Koeffizienten sind in Log-Odds angegeben

Interpretation

		Estimate	Std. Error	z value	Pr(> z)	
1						
2	(Intercept)	2.47359	0.06296	39.288	<2e-16	***
3	frequency_z	0.40610	0.04787	8.483	<2e-16	***
4	conditionrelated	0.25847	0.08956	2.886	0.0039	**

- Da Log-Odds für Menschen extrem unintuitiv sind, rechnen wir diese um

```
1 > plogis(2.47359)
2 [1] 0.9222695
```

- Für `frequency_z = 0` und die Referenzkategorie beträgt die vorhergesagte Wahrscheinlichkeit ca. 92 %

```
1 > exp(0.40610)
2 [1] 1.500953
```

- Mit jeder Erhöhung von `frequency_z` um eine Einheit werden die Odds einer korrekten Antwort mit 1.50 multipliziert = Die Odds sind etwa 50 % höher


Interpretation

- In vielen Anwendungen sind **predicted probabilities** am verständlichsten

```
1 newdat <- expand.grid(frequency_z = c(-1, 0, 1),
2                       condition = c("unrelated", "related"))
3
4 newdat$predicted_probability <- predict(m1, newdata = newdat,
5                                         type = "response")
6
7 frequency_z condition predicted_probability
8 1          -1 unrelated           0.8877037
9 2           0 unrelated           0.9222697
10 3           1 unrelated           0.9468332
11 4          -1  related           0.9110053
12 5           0  related           0.9388926
13 6           1  related           0.9584398
```

Interpretation

- In vielen Anwendungen sind **predicted probabilities** am verständlichsten



Interpretation

		Estimate	Std. Error	z value	Pr(> z)	
1						
2	(Intercept)	2.47359	0.06296	39.288	<2e-16	***
3	frequency_z	0.40610	0.04787	8.483	<2e-16	***
4	conditionrelated	0.25847	0.08956	2.886	0.0039	**

- Da Log-Odds für Menschen extrem unintuitiv sind, rechnen wir diese um

```
1 > plogis(2.47359)
2 [1] 0.9222695
```

- Und was ist mit kategorialen Variablen? Das Referenzlevel von `condition` is `unrelated` und damit im Intercept

```
1 > exp(0.25847)
2 [1] 1.294947
```

- Die Odds einer korrekten Antwort sind in `related` etwa 1.29-mal so hoch wie in `unrelated`

Nested models / verschachtelte Modelle

- Auch bei logistischer Regression kann man nested Modelle vergleichen

```
1 m0 <- glm(accuracy ~ frequency_z...
```

```
1 m1 <- glm(accuracy ~ frequency_z + condition...
```

- und entsprechend



```
1 > anova(m0, m1, test = "Chisq")
2 Analysis of Deviance Table
3
4 Model 1: accuracy ~ frequency_z
5 Model 2: accuracy ~ frequency_z + condition
6   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
7 1         7198      3828.2
8 2         7197      3819.8  1    8.3825 0.003788 **
```

Annahmen der logistischen Regression

- Keine Annahme, dass
 - die AV normalverteilt ist
 - die Prädiktoren normalverteilt sind
 - die Residuen normalverteilt sind
 - Homoskedastizität vorliegt
- Annahmen
 - binäre AV
 - unabhängige Beobachtungen
 - keine problematische Multikollinearität
 - ausreichend Daten / ausreichend Ereignisse
 - keine vollständige oder quasi-vollständige **Separation**
 - kontinuierliche Prädiktoren sollten **linear** mit dem Logit zusammenhängen
 - keine stark einflussreichen Beobachtungen

Linearität - aber mit dem Logit

- `frequency_z` muss nicht linear mit `accuracy` zusammenhängen
- Sondern `frequency_z` sollte linear mit den Log-Odds des Outcomes zusammenhängen



Separation

- Wenn ein Prädiktor die Gruppen perfekt trennt, versucht das Modell einen unendlich großen Koeffizienten zu schätzen
- Dadurch meckert R und das Modell wird instabil und unzuverlässig
- Separation ist relativ einfach zu erkennen, zum Beispiel

frequency	accuracy	frequency	accuracy
niedrig	0	hoch	1
niedrig	0	hoch	1
niedrig	0	hoch	1

Interaktionen

- Auch logistische Regressionen können Interaktionen enthalten
- Interaktionen auf der Logit-Skala sind noch weniger intuitiv als in der linearen Regression
→ am besten über vorhergesagte Wahrscheinlichkeiten visualisieren