

Gemischte Regression

GRK2700 Statistik-Workshop
am 25. August 2026

Dr. Dominic Schmitz
dominic.schmitz@hhu.de

Warum Mixed Models?

Gedankenexperiment


- Stell dir vor, dass du Elternteil von 6 Kindern bist
- Jedes Jahr misst du die Körpergröße deiner Kinder an ihren Geburtstagen

	Kate	Eve	Tess	Max	Neil	Jack
12	149.8	156.3	145.8	149.1	143.3	159.3
13	156.7	163.2	153.7	156.2	150.4	166.4
14	158.7	165.2	160.7	163.8	158.0	174
15	159.7	166.2	162.7	170.1	164.3	180.3
16	162.5	169.0	167.5	173.4	167.6	183.6
17	162.5	169.0	172.5	175.2	169.4	185.4
18	163.0	169.5	178.0	175.7	169.9	185.9

Gedankenexperiment

- Mit deinem Wissen über einfache lineare Regression erstellst du ein Model

```
1 lm(Größe ~ Alter, dat)
```




- Das Modell nimmt an, dass alle Kinder denselben Ausgangspunkt und denselben Zusammenhang zwischen Alter und Größe haben

Gedankenexperiment

- Mit deinem Wissen über multiple lineare Regression erstellst du ein Model


```
1 lm(Größe ~ Alter + bioGeschlecht, dat)
```



- Das Modell nimmt an, dass alle Kinder eines bio Geschlechts denselben Ausgangspunkt und denselben Zusammenhang zwischen Alter und Größe haben

Gedankenexperiment


- Aber stimmt das?



Gedankenexperiment

- Mit deinem Wissen über multiple lineare Regression erstellst du ein Model

```
1 lm(Größe ~ Alter + bioGeschlecht, dat)
```



i Was müssen wir tun, damit das Modell realistischer wird?

Das eigentliche statistische Problem

- Das eigentliche Problem: Die Beobachtungen sind nicht unabhängig
→ Messungen desselben Kindes ähneln sich stärker als Messungen verschiedener Kinder
- Dasselbe passiert in linguistischen Daten
 - dieselbe Versuchsperson → viele Tokens (bspw. gesprochen)
 - dasselbe Item → viele Versuchspersonen
 - derselbe Text → viele Beobachtungen
 - dasselbe Korpus → viele Attestierungen



Merke

100 Messungen derselben Person sind nicht dasselbe wie je 1 Messung von 100 unabhängigen Personen

Das eigentliche statistische Problem


```
1 head(dat)
2   subject item trial  RT accuracy
3 1      S01 W001    82 431        1
4 2      S01 W002     6 456        1
5 3      S01 W003   118 477        1
6 4      S01 W004    26 576        1
7 5      S01 W005   107 436        1
8 6      S01 W006    34 651        1
```

- Unsere Daten leiden unter genau diesem Problem
 - `item`: 120 Items, die von jeder VP bearbeitet wurden
 - `subject`: 60 VPs, die jeweils 120 Datenpunkte beitragen
- S.g. **Pseudoreplikation**
 - Wenn Daten als unabhängige Wiederholungen (Replikate) behandelt werden, obwohl sie in Wirklichkeit nicht unabhängig voneinander sind
 - Führt zu einer künstlich vergrößerten Stichprobengröße und falschen, oft zu positiven Testergebnissen

Gedankenexperiment

- Mit deinem (baldigen) Wissen über gemischte Regression erstellst du ein Model

```
1 lmer(Größe ~ Alter + bioGeschlecht + (1|Name), dat)
```




- Modell: Kinder gleichen bioGeschlechts teilen Eigenschaften, Alter beeinflusst alle Kinder, Kinder haben unterschiedliche Ausgangspunkte → realistischer!

Gedankenexperiment

- Mit deinem (baldigen) Wissen über gemischte Regression erstellst du ein Model

```
1 lmer(Größe ~ Alter + bioGeschlecht + (1|Name), dat)
```




i Reicht das schon?

Gedankenexperiment

- Mit deinem (baldigen) Wissen über gemischte Regression erstellst du ein Model


```
1 lmer(Größe ~ Alter + bioGeschlecht + (1+Alter|Name), dat)
```



- Modell: Jedes Kind darf sich sowohl im Ausgangsniveau als auch im Zusammenhang zwischen Alter und Körpergröße unterscheiden.

Gemischte Modelle

- Gemischte Modelle kombinieren
 - **Populationseffekte**, die uns interessieren, → fixed effects
 - mit Variation zwischen **Gruppierungseinheiten** → random effects



Gemischte Modelle

- Für unsere Daten sieht das dann bspw. so aus

```
1 lmer(RT ~ frequency_z + condition + length + (1|subject) +  
2 (1|item), dat)
```

- Tipp: Je mehr Variablen, desto ratsamer ist eine „lange“ Schreibweise

```
1 lmer(RT ~  
2     frequency_z +  
3     condition +  
4     length +  
5     (1|subject) +  
6     (1|item),  
7     dat)
```

- Dieses Modell erlaubt zwei Dinge
 1. VPs dürfen generell unterschiedlich schnell sein
 2. Wörter dürfen generell unterschiedlich schnell verarbeitet werden

Gemischte Modelle

- Warum also möchten wir gemischte Modelle verwenden?
- Sie helfen uns, wenn
 - wir wiederholte Messungen haben
 - Beobachtungen in Personen, Items usw. gruppiert sind
 - diese Einheiten sich systematisch voneinander unterscheiden
 - wir trotzdem über allgemeine Populationseffekte sprechen möchten

Fixed vs. Random Effects, Random Intercepts und Slopes

Mixed?

```
1 lmer(RT ~  
2     frequency_z +  
3     condition +  
4     length +  
5     (1|subject) +  
6     (1|item),  
7     dat)
```

- **Fixed Effects**

Effekte, deren konkrete Ausprägung bzw. Zusammenhang wir direkt schätzen und interpretieren möchten - auch Kontrollvariablen!

Mixed?

```
1 lmer(RT ~  
2     frequency_z +  
3     condition +  
4     length +  
5     (1|subject) +  
6     (1|item),  
7     dat)
```

- **Fixed Effects**

Effekte, deren konkrete Ausprägung bzw. Zusammenhang wir direkt schätzen und interpretieren möchten - auch Kontrollvariablen!

- **Random Effects**

Effekte, die Variation zwischen den Levels einer Gruppierungsvariable modellieren; i.d.R. interessiert uns ihre genaue Natur nicht (ist VP13 schneller als VP47?)

Fixed Effect vs. Random Effect

- Ob eine Variable als Fixed oder Random Effect eingesetzt wird, ist keine Eigenschaft der Variable
- Viel mehr ist es eine Frage des Designs und der Forschungsfrage
- Beispiel
 - Typischerweise wird die VP-ID als Random Effect eingesetzt
 - Theoretisch kann die VP-ID aber auch ein Fixed Effect sein, eben dann, wenn uns genau dieser Unterschied zwischen VPs interessiert



Merke

Fixed vs. Random hängt davon ab, welche inferenzielle Rolle eine Variable im Modell spielt

Gemischte Regression: Formel 1

Multiple Regression

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_i X_i + \epsilon$$

Einfache Regression

$$Y = \beta_0 + \beta_1 X_1 + \epsilon$$

Gemischte Regression: Formel 1

Einfache Regression

$$Y = \beta_0 + \beta_1 X_1 + \epsilon$$

Gemischte Regression

$$Y = \beta_0 + u_0 + \beta_1 X_1 + \epsilon$$

durchschnittlicher
Intercept

individuelle
Abweichung

Gemischte Regression: Intercept

- Nehmen wir an: Populationsintercept beträgt

650ms

- Versuchspersonen A und B

$$u_{0A} = -50; u_{0B} = 80$$

→ individueller Intercept


$$650 - 50 = 600\text{ms}$$

$$650 + 80 = 730\text{ms}$$

Gedankenexperiment

- Mit deinem (baldigen) Wissen über gemischte Regression erstellst du ein Modell

```
1 lmer(Größe ~ Alter + bioGeschlecht + (1+Alter|Name), dat)
```



- Modell: Jedes Kind darf sich sowohl im Ausgangsniveau als auch im Zusammenhang zwischen Alter und Körpergröße unterscheiden.

Gemischte Regression: Formel 2

Gemischte Regression mit Random Intercept

$$Y = \beta_0 + u_0 + \beta_1 X_1 + \epsilon$$

Gemischte Regression mit Random Intercept und Random Slope

$$Y = \beta_0 + u_0 + (\beta_1 + u_1)X_1 + \epsilon$$

durchschnittlicher
Effekt


Abweichung
jedes Levels
von X_1

→ **Steigungsanpassung**

Gedankenexperiment

- Mit deinem (baldigen) Wissen über gemischte Regression erstellst du ein Modell




```
1 lmer(Größe ~ Alter + bioGeschlecht + (1+Alter|Name), dat)
```



- Modell: Jedes Kind darf sich sowohl im Ausgangsniveau als auch im Zusammenhang zwischen Alter und Körpergröße unterscheiden.

Random Intercept vs. Random Slope

Syntax	Bedeutung
<code>(1 subject)</code>	Personen unterscheiden sich im Ausgangsniveau
<code>(1+frequency_z subject)</code>	zusätzlich unterschiedlich starke Frequency-Effekte
<code>(1+condition subject)</code>	zusätzlich unterschiedlich starke Condition-Effekte



Wann kann ein Random Slope sinnvoll sein?

Barr et al. (2013): „keep it maximal“

Alle Random Intercepts und Slopes einfügen, die irgendwie
linguistisch/theoretisch begründbar sind;

aber **oft interpretiert** als: Alle Random Intercepts und Slopes einfügen, egal
ob linguistisch/theoretisch begründbar



Winter (2019): „reflect on what the most appropriate model is,
given the data and given your theory“

Wann kann ein Random Slope sinnvoll sein?

- Meine Herangehensweise
 - Winter (2019): „reflect on what the most appropriate model is, given the data and given your theory“
 - Dann sinnvoll, wenn der betreffende Prädiktor innerhalb der Gruppierungseinheit variiert und wir erwarten können, dass sein Effekt zwischen den Einheiten variiert
 - Beispiel: Ich kann davon ausgehen, dass unterschiedliche Menschen unterschiedliche Erfahrungen mit Wörtern haben und diese entsprechend unterschiedlich verarbeiten

Wann kann ein Random Slope sinnvoll sein?

- Was ganz klar nicht funktioniert: Ein Random Slope, der den Daten widerspricht
- Beispiel: Jedes Item gehört nur einer der beiden Conditions an

Item	Condition A	Condition B
Haus	60	0
Maus	0	60
Laus	60	0
Raus	0	60

- So kann der Condition-Effekt nicht innerhalb desselben Items geschätzt werden

Na, aufgepasst?

 Was darf hier wie variieren?

```
1 lmer(RT ~  
2     frequency_z +  
3     condition +  
4     (1|subject) +  
5     (1|item),  
6     dat)
```

- Jede Versuchsperson darf eine eigene durchschnittliche RT haben
- Jedes Wort darf eine eigene durchschnittliche RT haben
- Der Effekt von `frequency_z` ist für alle Personen und Wörter gleich
- Der Effekt von `condition` ist für alle Personen und Wörter gleich

Na, aufgepasst?

Was darf hier wie variieren?

```
1 lmer(RT ~  
2       frequency_z +  
3       condition +  
4       (1+condition|subject) +  
5       (1|item),  
6       dat)
```

- Versuchspersonen dürfen sich in ihrer durchschnittlichen RT unterscheiden
- Wörter dürfen sich in ihrer durchschnittlichen RT unterscheiden
- Der Effekt von `condition` darf zwischen Versuchspersonen variieren
- Der Effekt von `frequency_z` ist für alle Versuchspersonen gleich
- Für Wörter wird kein unterschiedlicher `condition`-Effekt modelliert

Na, aufgepasst?

Was darf hier wie variieren?

```
1 lmer(RT ~  
2     frequency_z +  
3     condition +  
4     (1+condition|subject) +  
5     (1+frequency_z|item),  
6     dat)
```

- Versuchspersonen dürfen sich in ihrer durchschnittlichen RT unterscheiden
- Der Effekt von `condition` darf zwischen Versuchspersonen variieren
- Wörter dürfen sich in ihrer durchschnittlichen RT unterscheiden
- Der Effekt von `frequency_z` darf zwischen Wörtern variieren
- Zusätzlich wird getestet, ob der Effekt von `frequency_z` von `condition` abhängt

Mixed Models interpretieren

Unser Modell

```
1 library(lme4)
2 library(lmerTest)
3
4 m1 <- lmer(RT ~
5             frequency_z +
6             condition +
7             (1+condition|subject) +
8             (1|item),
9             dat)
```

- Jede Versuchsperson darf eine eigene durchschnittliche RT haben
- Jedes Wort darf eine eigene durchschnittliche RT haben
- Der Effekt von `frequency_z` ist für alle Personen und Wörter gleich
- Der Effekt von `condition` ist für alle Personen und Wörter gleich

Summary - Random Effects

```
1 Random effects:
2   Groups      Name                Variance Std.Dev.  Corr
3   item        (Intercept)         13932    118.04
4   subject     (Intercept)          9462     97.27
5               conditionrelated    1697     41.20   -0.02
6   Residual                                5978     77.31
7 Number of obs: 7200, groups:  item, 120; subject, 60
8
9 Fixed effects:
10                Estimate Std. Error      df t value Pr(>|t|)
11 (Intercept)      658.352    16.656 139.740   39.527  < 2e-16 ***
12 frequency_z     -52.234    11.575 117.530   -4.513 1.53e-05 ***
13 conditionrelated -35.271     5.622  57.635   -6.274 4.91e-08 ***
14 ---
15 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
16
17 Correlation of Fixed Effects:
18                (Intr) frqnc_
19 frequency_z    0.084
20 conditnrltd -0.031  0.000
```

Summary - Fixed Effects

```
1 Random effects:
2   Groups      Name                Variance Std.Dev.  Corr
3   item        (Intercept)         13932    118.04
4   subject     (Intercept)          9462     97.27
5               conditionrelated    1697     41.20   -0.02
6   Residual                                5978     77.31
7 Number of obs: 7200, groups:  item, 120; subject, 60
8
9 Fixed effects:
10              Estimate Std. Error      df t value Pr(>|t|)
11 (Intercept)      658.352      16.656 139.740   39.527  < 2e-16 ***
12 frequency_z     -52.234      11.575 117.530   -4.513 1.53e-05 ***
13 conditionrelated -35.271       5.622  57.635   -6.274 4.91e-08 ***
14 ---
15 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
16
17 Correlation of Fixed Effects:
18              (Intr) frqnc_
19 frequency_z    0.084
20 conditnrltd -0.031  0.000
```

Summary - Correlation of Fixed Effects

```
1 Random effects:
2   Groups      Name                Variance Std.Dev.  Corr
3   item        (Intercept)         13932    118.04
4   subject     (Intercept)          9462     97.27
5               conditionrelated    1697     41.20   -0.02
6   Residual                                5978     77.31
7 Number of obs: 7200, groups:  item, 120; subject, 60
8
9 Fixed effects:
10                Estimate Std. Error      df t value Pr(>|t|)
11 (Intercept)      658.352    16.656 139.740   39.527  < 2e-16 ***
12 frequency_z     -52.234    11.575 117.530   -4.513 1.53e-05 ***
13 conditionrelated -35.271     5.622  57.635   -6.274 4.91e-08 ***
14 ---
15 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
16
17 Correlation of Fixed Effects:
18                (Intr) frqnc_
19 frequency_z    0.084
20 conditnrltd -0.031  0.000
```

Summary - Fixed Effects

```
1 Fixed effects:
2               Estimate Std. Error      df t value Pr(>|t|)
3 (Intercept)    658.352    16.656 139.740  39.527 < 2e-16 ***
4 frequency_z   -52.234    11.575 117.530  -4.513 1.53e-05 ***
5 conditionrelated -35.271     5.622  57.635  -6.274 4.91e-08 ***
```

- Kennen wir schon
- Das Lesen der Werte funktioniert genauso wie bei multipler Regression ohne Random Effects
- Die `anova()` Funktion funktioniert ebenfalls so wie wir es bereits kennen

```
1 > anova(m1)
2 Type III Analysis of Variance Table with Satterthwaite's method
3               Sum Sq Mean Sq NumDF    DenDF F value    Pr(>F)
4 frequency_z 121728  121728     1 117.530  20.364 1.529e-05 ***
5 condition   235283  235283     1  57.635  39.361 4.907e-08 ***
```

Summary - Random Effects

1	Random effects:				
2	Groups	Name	Variance	Std.Dev.	Corr
3	item	(Intercept)	13932	118.04	
4	subject	(Intercept)	9462	97.27	
5		conditionrelated	1697	41.20	-0.02
6	Residual		5978	77.31	
7	Number of obs: 7200, groups: item, 120; subject, 60				

- Items unterscheiden sich deutlich in ihrer durchschnittlichen Reaktionszeit
- Die `item`-spezifischen Intercepts streuen mit etwa 118 ms um den Populationsintercept
- Manche Wörter werden also generell schneller, andere generell langsamer verarbeitet

Summary - Random Effects

```
1 Random effects:
2   Groups      Name                Variance Std.Dev.  Corr
3   item        (Intercept)         13932    118.04
4   subject     (Intercept)         9462     97.27
5   conditionrelated 1697          41.20   -0.02
6   Residual                    5978     77.31
7   Number of obs: 7200, groups:  item, 120; subject, 60
```

- Auch Versuchspersonen unterscheiden sich in ihrer durchschnittlichen Reaktionszeit
- Die `subject`-spezifischen Intercepts streuen mit etwa 97 ms um den Populationsintercept
- Manche Personen reagieren generell schneller, andere langsamer

Summary - Random Effects

```
1 Random effects:
2   Groups      Name                Variance Std.Dev.  Corr
3   item        (Intercept)         13932    118.04
4   subject     (Intercept)          9462     97.27
5               conditionrelated    1697     41.20   -0.02
6   Residual                                5978     77.31
7 Number of obs: 7200, groups:  item, 120; subject, 60
```

- Selbst nachdem Fixed und Random Effects berücksichtigt wurden, bleibt Variation zwischen einzelnen Beobachtungen übrig
- Diese verbleibende Variation hat eine geschätzte Standardabweichung von etwa 77 ms
- In der related-Bedingung sind RTs etwa 35 ms kürzer als in der Referenzbedingung (siehe Fixed Effects), aber eben nicht bei jeder Person exakt 35 ms

Summary - Random Effects

```
1 Random effects:
2   Groups      Name                Variance Std.Dev.  Corr
3   item        (Intercept)         13932    118.04
4   subject     (Intercept)          9462     97.27
5   conditionrelated 1697          41.20    -0.02
6   Residual                                5978     77.31
7 Number of obs: 7200, groups:  item, 120; subject, 60
```

- Der durchschnittliche `condition`-Effekt ist ein Fixed Effect
- Gleichzeitig darf dieser Effekt zwischen Versuchspersonen variieren
- Die individuellen `condition`-Effekte streuen mit einer SD von etwa 41 ms um den durchschnittlichen `condition`-Effekt

Summary - Random Effects

```
1 Random effects:
2   Groups      Name                Variance Std.Dev.  Corr
3   item        (Intercept)         13932    118.04
4   subject     (Intercept)          9462     97.27
5   conditionrelated 1697          41.20    -0.02
6   Residual                                5978     77.31
7 Number of obs: 7200, groups:  item, 120; subject, 60
```

- Die geschätzte Korrelation zwischen dem individuellen `subject`-Intercept und dem individuellen `condition`-Slope beträgt -0.02
→ Also praktisch kein Zusammenhang
 - Personen, die generell langsamer sind, zeigen nicht systematisch einen stärkeren oder schwächeren `condition`-Effekt
 - Ausgangsniveau und `condition`-Effekt sind in diesen Daten nahezu unabhängig voneinander
- Wichtig: Diese Korrelation ist **nicht der zentrale Hypothesentest** des Modells

Summary - Correlation of Fixed Effects

```
1 Correlation of Fixed Effects:  
2           (Intr)  frqnc_  
3 frequency_z    0.084  
4 conditnrltd -0.031   0.000
```

- Hier werden nicht die Variablen im Datensatz miteinander korreliert, sondern die geschätzten Fixed-Effect-Koeffizienten des Modells
- Die Tabelle beschreibt, wie stark die Unsicherheiten dieser Parameterschätzungen miteinander zusammenhängen
- Mit anderen Worten: Wenn sich die Schätzung eines Koeffizienten aufgrund der Daten etwas verändern würde: Wie stark würde sich dabei typischerweise auch die Schätzung eines anderen Koeffizienten verändern?

Summary - Correlation of Fixed Effects

```
1 Correlation of Fixed Effects:  
2           (Intr) frqnc_  
3 frequency z  0.084  
4 conditnrltd -0.031  0.000
```

- Sehr schwache positive Korrelation
- Die Schätzung des `frequency`-Effekts und die Schätzung des Intercepts hängen praktisch kaum voneinander ab

Summary - Correlation of Fixed Effects

```
1 Correlation of Fixed Effects:  
2           (Intr) frqnc_  
3 frequency_z  0.084  
4 conditnr1td -0.031  0.000
```

- Sehr schwache negative Korrelation
- Ebenfalls praktisch kein Zusammenhang der beiden Parameterschätzungen

Summary - Correlation of Fixed Effects

```
1 Correlation of Fixed Effects:  
2           (Intr) frqnc_  
3 frequency_z  0.084  
4 conditnrltd -0.031  0.000
```

- = `conditionrelated` × `frequency_z`
- Praktisch gar keine Korrelation
- Die Schätzung des `condition`-Effekts ist hier praktisch unabhängig davon, wie groß der `frequency`-Effekt geschätzt wird

Summary - Correlation of Fixed Effects

```
1 Correlation of Fixed Effects:  
2           (Intr) frqnc_  
3 frequency_z  0.084  
4 conditnrltd -0.031  0.000
```

- Warum gibt `lmer()` das überhaupt aus?
→ Weil Regressionskoeffizienten gemeinsam geschätzt werden
- Dadurch können die Schätzungen miteinander gekoppelt sein
- Beispiel: Zwei Prädiktoren enthalten sehr ähnliche Information
 - Dann könnte das Modell beispielsweise einen etwas größeren Effekt für X_1 und dafür einen etwas kleineren für X_2 schätzen (oder umgekehrt)
 - Die Koeffizientenschätzungen wären dann stärker miteinander korreliert



Merke

Correlation of Fixed Effects $\neq$ Korrelation zwischen den Variablen