


Kollinearität

GRK2700 Statistik-Workshop
am 25. August 2026

Dr. Dominic Schmitz
dominic.schmitz@hhu.de


Kollinearität: Was ist das Problem?

- In Regressionsmodellen versuchen wir, den einzigartigen Effekt jedes Prädiktors zu schätzen




Kollinearität: Was ist das Problem?

- Was passiert, wenn die Prädiktoren selbst stark zusammenhängen?



Was ist Kollinearität?

- Kollinearität liegt vor, wenn Prädiktoren eines Modells überlappende Information enthalten
- Also bei zwei (oder mehr) sehr stark zusammenhängenden Variablen



- Wichtig dabei: Die Variablen müssen...
 - nicht identisch sein, nicht dieselben Eigenschaften/Sachen beschreiben
 - nur so stark zusammenhängen, dass es schwierig wird, ihre individuellen Beiträge auseinanderzuhalten → starke Korrelation

Was ist Kollinearität?

- Angenommen

```
1 lm(log_RT ~ frequency_z + neighbourhood_z, dat)
```

- Die Koeffizienten des Modells beantworten uns
 - Wie verändert sich RT mit `frequency`, wenn `neighbourhood` konstant gehalten wird?
 - Wie verändert sich RT mit `neighbourhood`, wenn `frequency` konstant gehalten wird?
- Problem: Wenn `frequency` und `neighbourhood` fast immer gemeinsam steigen, gibt es nur wenige Beobachtungen, anhand derer das Modell diese beiden Fragen voneinander trennen kann

Unser Datensatz

	Frequency	Length	Neighbourhood	Condition
Frequency	1.000	-0.590	0.875	0.000
Length	-0.590	1.000	-0.534	0.000
Neighbourhood	0.875	-0.534	1.000	0.000
Condition	0.000	0.000	0.000	1.000

- Die Diagonale ist immer 1, da jede Variable mit sich selbst perfekt korreliert

Unser Datensatz

	Frequency	Length	Neighbourhood	Condition
Frequency		-0.590	0.875	0.000
Length	-0.590		-0.534	0.000
Neighbourhood	0.875	-0.534		0.000
Condition	0.000	0.000	0.000	

- Nicht jede Korrelation ist gleich problematisch
 - praktisch unabhängig: `condition ↔ frequency`
 - moderater Zusammenhang: `length ↔ neighbourhood`
`length ↔ frequency`
 - starker Zusammenhang: `frequency ↔ neighbourhood`

Unser Datensatz

	Frequency	Length	Neighbourhood	Condition
Frequency		-0.590	0.875	0.000
Length	-0.590		-0.534	0.000
Neighbourhood	0.875	-0.534		0.000
Condition	0.000	0.000	0.000	

- Besonders stark korreliert sind damit `frequency` und `neighbourhood`
- Ist das überraschend? Eher nicht
 - Bei lexikalischen Variablen entstehen Zusammenhänge häufig nicht zufällig
 - Häufige Wörter können dichter in lexikalischen Räumen liegen
 - Wortlänge hängt mit Frequenz zusammen
 - Frequenz hängt wiederum mit Nachbarschaftsdichte zusammen

Was ist das statistische Problem?

- Kollinearität hat vier hauptsächliche Konsequenzen

1. **Koeffizienten verändern sich**

Ein Teil des Effekts muss zwischen Prädiktoren aufgeteilt werden

2. **Standardfehler werden größer**

Die individuelle Schätzung wird unpräziser

3. **Konfidenzintervalle werden breiter**

Wir wissen weniger genau, wie groß der einzigartige Effekt ist

4. **Ergebnisse können modellabhängiger werden**

Ein Koeffizient kann sich deutlich ändern, wenn ein korrelierter Prädiktor hinzugefügt oder entfernt wird

Beispiel: Frequency und Neighbourhood

```
1 lm(RT ~ frequency_z + length_z + condition, data = dat)
2
3 frequency_z          -40.451
4 length_z             18.580
5 conditionunrelated   35.271
```

- **+1 SD frequency** → ca. 40 ms kürzere RT, wenn length und condition konstant sind

```
1 lm(RT ~ neighbourhood_z + length_z + condition, data = dat)
2
3 neighbourhood_z      -39.336
4 length_z             19.891
5 conditionunrelated   35.271
```

- **+1 SD neighbourhood** → ca. 39 ms kürzere RT, wenn length und condition konstant sind


Beispiel: Frequency und Neighbourhood

```
1 lm(RT ~ frequency_z +  
2     neighbourhood_z +  
3     length_z + condition,  
4     data = dat)  
5  
6 frequency_z           -13.062  
7 neighbourhood_z      -29.780  
8 length_z             17.789  
9 conditionunrelated    35.271
```

- $\Delta\text{Freq} = \text{Freq}_{\text{allele}} - \text{Freq}_{\text{beide}} = 40.451 - 13.062 = 27.389$
- $\Delta\text{Neigh} = \text{Neigh}_{\text{allele}} - \text{Neigh}_{\text{beide}} = 39.336 - 29.780 = 9.559$

Beispiel: Frequency und Neighbourhood

- Warum verändert sich `frequency` so stark?
- `frequency` erhält sowohl ihre eigene Information als auch Information, die sie mit `neighbourhood` teilt
- Der `frequency`-Koeffizient beschreibt nur noch den Anteil, der über `neighbourhood` hinaus mit RT zusammenhängt



Nicht nur β verändert sich

	ohne anderen Prädiktor	gemeinsam
Frequency β	-40.45	-13.06
Frequency SE	2.69	4.68
Neighbourhood β	-39.34	-29.78
Neighbourhood SE	2.39	4.18



Merke

Kollinearität betrifft sowohl die Größe als auch die Präzision individueller Koeffizienten

...und die anderen Prädiktoren?

	β length
Frequency-Modell	18.58
Neighbourhood-Modell	19.89
beide im Modell	17.79

- Obwohl `length` und die beiden anderen Prädiktoren mit ca. 0.56 korreliert sind, ist der Koeffizient relativ stabil



Merke

Eine sichtbare Korrelation bedeutet nicht automatisch dramatische Kollinearität

- ...`condition` schauen wir uns gar nicht erst an, da ist alles stabil

Kollinearität und Signifikanz


- Im gemeinsamen Modell zeigen beide Variablen, `frequency` und `neighbourhood`, einen signifikanten Effekt
- Trotzdem
 - `frequency` β verändert sich massiv
 - SE steigt stark
 - VIF liegt bei 4.69



Merke

Kollinearität diagnostizieren wir nicht anhand von p-Werten

Beispiel: Frequency und Neighbourhood



- Wie viel zusätzliche Information liefert frequency dann überhaupt noch?
 - Modell mit `neighbourhood`
$$R^2 = 0.0951$$
 - Modell mit `neighbourhood` und `frequency`
$$R^2 = 0.0961$$
 - `frequency` erklärt also zusätzlich nur extrem wenig Varianz, $\Delta R^2 = 0.001$, zeigt aber einen signifikanten Effekt



Merke

Signifikanz $\neq$ großer Effekt

Generelles Vorgehen

- Vor dem Erstellen eines Modells **Korrelationen** prüfen hilft dabei
 - stark zusammenhängende numerische Prädiktoren zu finden
 - mögliche Designprobleme zu erkennen
 - zu verstehen, warum später Koeffizienten instabil sein könnten
- Aber: Eine Korrelationsmatrix betrachtet immer nur Paare
 - Ein Prädiktor kann möglicherweise durch mehrere andere Prädiktoren gemeinsam sehr gut vorhergesagt werden
- Deshalb: Kollinearität auch im tatsächlichen Modell untersuchen

Generelles Vorgehen

1	Term	VIF	VIF 95% CI	adj. VIF	Tolerance	Tolerance 95% CI
2	frequency_z	4.69	[4.50, 4.89]	2.17	0.21	[0.20, 0.22]
3	neighbourhood_z	4.27	[4.10, 4.45]	2.07	0.23	[0.22, 0.24]
4	length_z	1.54	[1.49, 1.59]	1.24	0.65	[0.63, 0.67]
5	condition	1.00	[1.00,]	1.00	1.00	[, 1.00]

- Im tatsächlichen Modell lassen sich die **Variance Inflation Factors** untersuchen

$$\text{VIF} = \frac{1}{1 - R^2}$$

- Dabei sagt R^2 aus, wie gut der jeweilige Prädiktor durch alle anderen Prädiktoren vorhergesagt werden kann
- Daher: $R^2 \uparrow \text{VIF} \uparrow$
- Ab wann ist ein VIF-Wert problematisch? 3? 5? 10?
→ Es gibt keinen universellen Cut-Off

Keine One-size-fits-all-Lösung

- Mögliche Strategien im Umgang mit Kollinearität
 1. nichts ändern
 2. einen Prädiktor wählen, den anderen ausschließen
 3. Variablen zusammenfassen / PCA / Dimensionsreduktion
 4. Forschungsfrage entsprechend formulieren
- ⚠ Die Ursache der Kollinearität bestimmt nicht automatisch ihre Lösung

Möglichkeit 1: Beide behalten

- Sinnvoll wenn
 - beide theoretisch wichtig sind
 - die Forschungsfrage gerade den einzigartigen Effekt betrifft
 - der VIF tolerierbar erscheint
 - genügend Daten vorhanden sind
- Beispiel: Hat `frequency` einen Effekt auf RT über `neighbourhood` hinaus?
→ Dann müssen beide ins Modell

Möglichkeit 2: Eine Variable auswählen

- Sinnvoll, wenn zwei Variablen praktisch dieselbe Information operationalisieren
 - Entscheidung anhand von
 - Theorie
 - Messvalidität
 - Reliabilität
 - Interpretierbarkeit
 - ggf. Modellfit
 - Nicht: Ich behalte einfach die Variable mit dem kleineren p-Wert
- ⚠ Wenn viele Variablen stark korelliert sind, verliert man hierdurch viele Variablen

Möglichkeit 3: Variablen zusammenfassen


- Sinnvoll, wenn mehrere Variablen ein gemeinsames Konstrukt repräsentieren
- Beispiele
 - mehrere Fragebogenitems
 - verschiedene Messungen desselben Konstrukts
 - mehrere stark überlappende lexikalische Maße
 - verschiedene Arten von „Frequenz“
- Möglichkeiten
 - Mittelwert
 - miteinander verrechnen
 - miteinander kombinieren → PCA

PCA: Principal Component Analysis

- Eine **Principal Component Analysis** transformiert mehrere korrelierte Variablen in neue, voneinander unkorrelierte Komponenten
- Alt: `frequency, length, neighbourhood`
- Neu: Principal Component 1, PC2, PC3
- Dabei: $\text{cor}(\text{PC}_1, \text{PC}_2) = 0$


PCA: Principal Component Analysis

- Eine PCA löscht keine Beobachtungen
- Stattdessen bekommt jede Beobachtung neue Koordinaten
- Wegen $r = .875$ liegen die Punkte ungefähr entlang einer Diagonalen
- Die PCs sind Linearkombinationen der ursprünglichen Variablen




PCA: Principal Component Analysis

- PC1 wird so gewählt, dass entlang dieser Achse möglichst viel Varianz der ursprünglichen Daten liegt



PCA: Principal Component Analysis

- PC2 wird so gewählt, dass möglichst viel der verbleibenden Varianz erklärt wird, und ist dabei orthogonal zu PC1 → keine Korrelation



PCA: Principal Component Analysis

- In R ist eine PCA unkompliziert gerechnet

```
1 pca <- prcomp(dat[, c("frequency_z",  
2                       "length_z",  
3                       "neighbourhood_z")],  
4                       scale. = FALSE
```

- Skalieren, wenn die Variablen noch nicht skaliert sind
- Nicht skalieren, wenn die Variablen schon skaliert sind

PCA: Principal Component Analysis

- Eine PCA erstellt so viele neue Variablen wie alte bereitgestellt werden
- Demnach reduziert eine PCA die Dimensionen nicht automatisch
- Die Dimensionsreduktion wird durch uns vorgenommen
- Jede weitere PC erklärt weniger Varianz als die vorangehende, in unserem Fall

	erklärte Varianz
PC1	77.720
PC2	18.342
PC3	3.938

- Die ersten beiden PCs enthalten bereits 96.1 % der Information bzw. Varianz der drei ursprünglichen Variablen

PCA: Principal Component Analysis

- Was bedeutet „77.7 % Varianz“ genau?
 - Die drei ursprünglichen Variablen variieren gemeinsam
 - PC1 findet die Richtung, entlang derer diese Variation am stärksten ist
 - Wenn wir nur PC1 behalten, erhalten wir bereits rund 78 % der Streuungsinformation, die ursprünglich über drei Variablen verteilt war
 - Gleichzeitig gehen rund 22 % verloren, wenn wir nur PC1 behalten

	erklärte Varianz
PC1	77.720
PC2	18.342
PC3	3.938

PCA: Principal Component Analysis

```
1 > summary(pca)
2 Importance of components:
3           PC1      PC2      PC3
4 Standard deviation 1.4943 0.7259 0.33635
5 Proportion of Variance 0.7772 0.1834 0.03938
6 Cumulative Proportion 0.7772 0.9606 1.00000
```

- **Proportion of Variance**

Anteil der ursprünglichen Streuung, die erklärt wird

- **Cumulative Proportion**

Summe der bisherigen Proportion of Variance

- **Standard deviation**


$$\text{Eigenwert} = 1.4943^2 \approx 2.23$$

größer als 1
→ erklärt mehr Varianz als
die PC selbst mitbringt

$$\text{Proportion of Variance} = \frac{2.23}{3} \approx 0.777$$

PCA: Principal Component Analysis

- Wie viele PCs behalten?
- Dazu gibt es mehrere Anhaltspunkte, keine festen Regeln
 1. erklärte Gesamtvarianz, oftmals 80% oder mehr
 2. Scree Plot, nach „Knick“ suchen
 3. Kaiser-Kriterium, Eigenwert > 1
 4. Interpretierbarkeit, kann man die PC verstehen?
- Und im konkreten Fall? Wohl 1 oder 2



PCA: Principal Component Analysis

- Und was bedeuten die PCs jetzt?

```
1 > pca$rotation
2           PC1      PC2      PC3
3 frequency_z  0.5844505 0.2939254 0.7563236
4 length_z    -0.5280433 0.8454910 0.0794685
5 neighbourhood_z 0.6161070 0.4458171 -0.6493530
```

- Je größer der Betrag eines **Loadings**, desto stärker trägt diese Variable zur Komponente bei

PCA: Principal Component Analysis

- Und was bedeuten die PCs jetzt?

```
1 > pca$rotation
2
3 frequency_z 0.5844505 0.2939254 0.7563236
4 length_z -0.5280433 0.8454910 0.0794685
5 neighbourhood_z 0.6161070 0.4458171 -0.6493530
```

- höhere frequency
- größere neighbourhood
- geringere length

→ häufige, kurze Wörter mit dichter neighbourhood

⚠ Nicht das absolute Vorzeichen einer PC ist interessant, sondern die relativen Beziehungen zwischen den Loadings!

PCA: Principal Component Analysis

- Und was bedeuten die PCs jetzt?

```
1 > pca$rotation
2           PC1      PC2      PC3
3 frequency_z  0.5844505  0.2939254  0.7563236
4 length_z    -0.5280433  0.8454910  0.0794685
5 neighbourhood_z 0.6161070  0.4458171 -0.6493530
```

- längere Wörter (sehr hohe Ladung!)
- tendenziell größere `neighbourhood`
- etwas höhere `frequency`
- Hier merkt man: PCs müssen nicht schön interpretierbar sein

PCA: Principal Component Analysis

- Loadings $\neq$ Scores
- Loadings haben wir uns gerade angesehen
- **Scores** sagen aus, wo jede Beobachtung auf der neuen PC liegt
- D.h. Scores sind die Werte der PCs, die wir dann bspw. in Regressionsanalysen verwenden

```
1 lm(RT ~ PC1 + PC2 + condition, dat)
```

PCA: Principal Component Analysis

- Statt 3 korrelierter Prädiktoren haben wir nun 2 orthogonale Prädiktoren
- Vorteile
 - Kollinearität beseitigt
 - Dimensionalität reduziert
 - fast alle ursprüngliche Varianz erhalten
 - stabilere Koeffizienten möglich

PCA: Principal Component Analysis

1	Estimate	Std. Error	t value	Pr(> t)		
2	(Intercept)	629.376	2.857	220.277	<2e-16	***
3	PC1	-35.375	1.352	-26.162	<2e-16	***
4	PC2	-2.075	2.783	-0.745	0.456	
5	conditionunrelated	35.271	4.041	8.729	<2e-16	***

- PC1 zeigt einen signifikanten Effekt, aber was sagt der aus?
- Höhere Werte auf der kombinierten Dimension aus höherer `frequency`, höherer `neighbourhood` und geringerer `length` gehen mit kürzeren RT einher
- Die höhere Komplexität der Interpretation ist der Preis der PCA



Merke

PCA ist nicht einfach ein technischer Trick, mit dem man dasselbe Modell „repariert“, sie verändert die Interpretationsmöglichkeit und damit gewissermaßen auch die Forschungsfrage

PCA: Principal Component Analysis

- Wann ist PCA besonders sinnvoll?
 - viele stark korrelierte Maße
 - Variablen gehören zu einem gemeinsamen Merkmalsraum
 - Einzelkoeffizienten sind nicht zentral
 - Dimensionsreduktion ist erwünscht
 - Prediction / summarische Struktur ist wichtig
- Wann ist PCA **nicht** sinnvoll?
 - Wenn die Forschungsfrage explizit nach der Wirkung einer bestimmten Variable fragt, sollte diese nicht ihren Weg in eine PCA finden

Keine One-size-fits-all-Lösung

- Mögliche Strategien im Umgang mit Kollinearität
 1. nichts ändern
 2. einen Prädiktor wählen, den anderen ausschließen
 3. Variablen zusammenfassen / PCA / Dimensionsreduktion

Keine One-size-fits-all-Lösung

- Mögliche Strategien im Umgang mit Kollinearität
 1. nichts ändern
wenn: Hat Frequency einen Effekt über Neighbourhood hinaus?
 2. einen Prädiktor wählen, den anderen ausschließen
 3. Variablen zusammenfassen / PCA / Dimensionsreduktion

Keine One-size-fits-all-Lösung

- Mögliche Strategien im Umgang mit Kollinearität

1. nichts ändern

wenn: Hat Frequency einen Effekt über Neighbourhood hinaus?

2. einen Prädiktor wählen, den anderen ausschließen

wenn: Welcher der beiden Prädiktoren eignet sich besser als Kontrollvariable?

3. Variablen zusammenfassen / PCA / Dimensionsreduktion

Keine One-size-fits-all-Lösung

- Mögliche Strategien im Umgang mit Kollinearität
 1. nichts ändern
wenn: Hat Frequency einen Effekt über Neighbourhood hinaus?
 2. einen Prädiktor wählen, den anderen ausschließen
wenn: Welcher der beiden Prädiktoren eignet sich besser als Kontrollvariable?
 3. Variablen zusammenfassen / PCA / Dimensionsreduktion
wenn: Können mehrere lexikalische Maße zu wenigen Dimensionen zusammengefasst werden?

Kollinearität: Take-Home

- Prädiktoren können Information teilen
- Dadurch werden individuelle Koeffizienten schwerer zu schätzen
- Hohe Korrelation $\neq$ automatisch unbrauchbares Modell
- VIF quantifiziert die Inflation der Unsicherheit im tatsächlichen Modell
- Die Forschungsfrage bestimmt die angemessene Reaktion

PCA: Take-Home

- PCA erzeugt neue, unkorrelierte Komponenten
- PC1 erklärt maximal mögliche Varianz, PC2 maximal verbleibende Varianz usw.
- Eigenwerte bzw. erklärte Varianz helfen bei der Entscheidung, wie viele PCs behalten werden
- Loadings helfen, PCs zu interpretieren
- Scores sind die Werte der Beobachtungen auf den PCs
- PCA löst Kollinearität mathematisch, aber verändert die Interpretation

Typischer Workflow

