

Modelldiagnostik & Modellkomplexität

GRK2700 Statistik-Workshop
am 25. August 2026

Dr. Dominic Schmitz
dominic.schmitz@hhu.de

Modelldiagnostik & Modellkomplexität

- Ein Modell zu berechnen ist nur der erste Schritt
- Danach müssen wir fragen
 - Passt das Modell angemessen zu unseren Daten?
 - Gibt es Beobachtungen, die unsere Ergebnisse stark beeinflussen?
 - Ist das Modell zu einfach?
 - Ist das Modell vielleicht zu komplex?
 - Bleiben unsere Schlussfolgerungen robust?

Modelldiagnostik & Modellkomplexität

```
1 > summary(m1)
2
3 Coefficients:
4             Estimate Std. Error t value Pr(>|t|)
5 (Intercept)    624.501      2.885  216.474 < 2e-16 ***
6 frequency_z   -40.451      2.687  -15.052 < 2e-16 ***
7 length_z      18.580      2.511    7.399 1.52e-13 ***
8 conditionunrelated 35.271      4.054    8.700 < 2e-16 ***
```

- Unser Modell zeigt
 - plausible Koeffizienten
 - kleine p-Werte
 - einen signifikanten Gesamteffekt
- Können wir das Ergebnis jetzt einfach berichten? → Nein
 - Ein statistisch signifikanter Effekt garantiert nicht, dass das zugrunde liegende Modell angemessen ist

Drei Fragen an jedes Modell

1. Passt die Modellform zu den Daten?
→ Modelldiagnostik
 2. Wird das Ergebnis von einzelnen Beobachtungen dominiert?
→ Influence Diagnostics
 3. Ist die Modellkomplexität angemessen?
→ Underfitting / Overfitting / Konvergenz / Singularität
- Wir untersuchen, ob Eigenschaften der Daten unsere Modellschätzung oder Inferenz problematisch beeinflussen

Residuen als Diagnoseinstrument


- Für Beobachtung i :

$$e_i = y_i - \hat{y}_i$$

- y_i : tatsächlich beobachteter Wert
- $\hat{y}_i$: vom Modell vorhergesagter Wert
- e_i : Residuum
- Das Residuum zeigt, wie weit das Modell für eine einzelne Beobachtung danebenliegt

Residuen als Diagnoseinstrument

- Beobachtung oberhalb der Modellvorhersage → positives Residuum
- Beobachtung unterhalb der Modellvorhersage → negatives Residuum
- perfekte Vorhersage → Residuum = 0




- Entscheidend ist aber nicht nur, wie groß Residuen sind, sondern ob sie systematische Muster zeigen

Residuen als Diagnoseinstrument

- Entscheidend ist aber nicht nur, wie groß Residuen sind, sondern ob sie systematische Muster zeigen
- Wieso das?
- Ein gutes Modell sollte relevante systematische Struktur der Daten erfassen
 - In den Residuen sollte deshalb möglichst kein deutliches systematisches Muster mehr vorhanden sein

Residuen als Diagnoseinstrument


- Eine der wichtigsten Darstellungen: Residuen gegen vorhergesagte Werte
- Ideal
 - Residuen liegen ungefähr um 0
 - keine deutliche Krümmung
 - ungefähr gleichmäßige Streuung
 - keine isolierten extremen Beobachtungen



Diagnoseplots


- Was wir sehen möchten

- keine systematische Struktur
- Residuen ungefähr symmetrisch um 0
- LOESS-Linie ungefähr horizontal
- ungefähr konstante Streuung




- Was wir **nicht** sehen möchten

- Muster und systematische Krümmung



Diagnoseplots

- Das ursprüngliche Modell war nicht grundsätzlich „schlecht“, sondern zu restriktiv
- Mit angepasster Modellspezifikation sind die Residuen völlig in Ordnung verteilt



Einflussreiche Beobachtungen

- **Outlier**

Beobachtung mit ungewöhnlich großem Residuum

- **High leverage point**

Beobachtung mit ungewöhnlichen Prädiktorwerten

- **Influential observation**


Beobachtung, deren Vorhandensein die geschätzten Modellparameter deutlich beeinflusst



Merke


Outlier $\neq$ automatisch influential

Einflussreiche Beobachtungen



Einflussreiche Beobachtungen

- **Cook's Distance** kombiniert Information darüber,
 - wie ungewöhnlich eine Beobachtung ist und
 - wie stark sie die Modellschätzung beeinflusst
- „Wie sehr würde sich mein Modell verändern, wenn diese Beobachtung nicht vorhanden wäre?“



Einflussreiche Beobachtungen

- Aber Achtung: Eine einflussreiche Beobachtung ist zunächst ein Diagnosehinweis
- Wir müssen uns fragen
 - Ist die Beobachtung ein Datenfehler?
 - Ist sie inhaltlich plausibel?
 - Warum hat sie so großen Einfluss?
 - Ändert sie unsere Schlussfolgerung?



Merke

Keine Regel: Cook's D groß → Beobachtung entfernen

Einflussreiche Beobachtungen

- Was passiert ohne die Beobachtung? → Sensitivitätsanalyse
- Vergleiche das Modell
 - mit der Beobachtung
 - ohne die Beobachtung
- und frage: Bleibt unsere grundsätzliche Schlussfolgerung gleich?

```
1 > coef(m_full)
2 (Intercept)          x
3   8.420516    3.451495
4 > coef(m_without)
5 (Intercept)          x
6  10.322935    3.041835
```

Robuste Ergebnisse

- Ein Ergebnis ist besonders überzeugend, wenn die zentrale Schlussfolgerung nicht vollständig davon abhängt,
 - ob eine einzelne Beobachtung enthalten ist,
 - welche plausible Modellspezifikation verwendet wird,
 - welche vertretbare Transformation gewählt wird
- Robustheit bedeutet nicht, dass alle Modelle exakt dieselben Koeffizienten liefern
- Entscheidend ist, ob sich die wissenschaftliche Interpretation fundamental verändert

Ein Modell kann zu einfach/komplex sein

- Das haben wir bereits gesehen: Ein lineares Modell konnte einen gekrümmten Zusammenhang nicht darstellen
→ **Underfitting**
- Wir könnten unserem Modell immer mehr erlauben
 - mehr Prädiktoren
 - mehr Interaktionen
 - mehr Random Slopes
 - mehr Random-Effect-Korrelationen
- Aber: Mehr Flexibilität ist nicht kostenlos

Ein Modell kann zu einfach/komplex sein

Underfitting	angemessen	Overfitting
zu einfach	relevante Struktur modelliert	zu flexibel
systematische Struktur bleibt übrig	guter Kompromiss	modelliert auch Zufallsrauschen
schlechter Fit	generalisierbar	instabile Vorhersagen

- Das Ziel ist nicht das komplizierteste Modell und auch nicht das einfachste Modell, sondern das Modell, das angemessen einfach/komplex ist

Modellqualität

- **R^2**
belohnt besseren Fit
- **Adjusted R^2**
berücksichtigt zusätzlich, wie viele Parameter dafür benötigt werden
- **AIC**
belohnt besseren Fit bei möglichst wenig unnötiger Komplexität
 - AIC ist anders als R^2 bzw. Adjusted R^2 eine relative Kennzahl
 - Ein AIC von 20,000 ist allein weder gut noch schlecht; er ist nur in Relation zu einem anderen AIC interpretierbar
- **BIC**
wie AIC, bestraft zusätzliche Parameter bei großen Stichproben stärker

Mixed Models sind komplex

- Bei Mixed Models kann Komplexität zusätzlich entstehen durch
 - Random Intercepts
 - Random Slopes
 - mehrere Gruppierungsvariablen
 - Korrelationen zwischen Random Effects
- Deswegen kann ein Modell zwar theoretisch sinnvoll erscheinen, praktisch jedoch für die vorhandenen Daten zu komplex sein

Konvergenz

- Bei der Modellschätzung sucht ein Optimierungsalgorithmus nach den Parameterwerten, bei denen das Modell optimal an die Daten angepasst ist
- **Konvergenz**
Der Algorithmus hat eine stabile Lösung gefunden
- **Konvergenzwarnung**
R kann nicht sicher feststellen, dass eine verlässliche optimale Lösung erreicht wurde

Konvergenz

- Eine Konvergenzwarnung ist keine Dekoration - nicht einfach ignorieren!
- Die ausgegebenen Koeffizienten können zwar plausibel aussehen, aber die Parameterschätzung ist möglicherweise numerisch instabil
- Mögliche Ursachen
 - Modell zu komplex
 - zu wenig Information für bestimmte Parameter
 - ungünstige Skalierung
 - stark korrelierte Parameter
 - numerische Optimierungsprobleme

Konvergenz

- Konvergenzwarnung - und jetzt?
 1. Warnung genau lesen
 2. Skalierung kontinuierlicher Prädiktoren prüfen
 3. Random-Effects-Struktur prüfen
 4. anderen Optimizer als Diagnose ausprobieren
 - Wenn mehrere Optimizer Schwierigkeiten haben, ist das ein starkes Signal, die Modellstruktur genauer anzusehen
 5. gegebenenfalls begründet vereinfachen

Singularität



- Auch ein konvergierendes Modell kann Probleme haben: **Singularität**
- Singularität liegt vor, wenn ein gemischtes Modell komplexere Random Effects enthält als von den Daten unterstützt werden

```
1 Random effects:
2   Groups      Name                Std.Dev.
3   subject    (Intercept)         95.4
4               condition           0.000
```

- Wir haben dem Modell erlaubt, dass VPs unterschiedliche `condition`-Effekte haben dürfen
- Das Modell schätzt aber, dass dem gar nicht so ist
→ Die Daten liefern praktisch keine Evidenz für die entsprechende zusätzliche Random-Effect-Dimension

Singularität

- Ein Random Slope ist nur sinnvoll schätzbar, wenn zwischen den Gruppen tatsächlich genügend Information über unterschiedliche Steigungen vorhanden ist



Singularität

- Liegt Singularität vor, sollte man die Random-Effects-Struktur bearbeiten

```
1 (1 + condition | subject)
```

- Korrelationen nicht schätzen, werden als 0 angenommen

```
1 (1 + condition || subject)
```

- nicht unterstützten Slope entfernen

```
1 (1 | subject)
```

- Aber: Nicht so lange Komponenten löschen, bis keine Warnung mehr erscheint
→ Vereinfachungen sollten mit Design, Forschungsfrage und Diagnostik begründet werden

Mixed Models vergleichen

- Wenn wir gemischte Modelle mit unterschiedlichen Fixed Effects vergleichen, sollten sie mit derselben Maximum-Likelihood geschätzt werden

```
1 m0 <- lmer(RT ~ frequency_z + (1 | subject),  
2           data = dat,  
3           REML = FALSE)  
4  
5 m1 <- lmer(RT ~ frequency_z + condition + (1 | subject),  
6           data = dat,  
7           REML = FALSE)
```

- Standardmäßig ist hier TRUE eingestellt
→ **Residual Maximum Likelihood**, und das ist eben abhängig von den enthaltenen Prädiktoren

Typischer Workflow


1. Modell spezifizieren
2. Output kontrollieren
3. Annahmen/Residuen prüfen
4. Kollinearität prüfen
5. Auffällige Beobachtungen prüfen
6. Gemischte Modelle: Konvergenz & Singularität
7. plausible Alternativmodelle vergleichen

Typischer Workflow

- Und wenn etwas auffällig ist?

Befund	mögliche Erklärung	mögliche Reaktion
gekrümmte Residuen	Modellform zu einfach	andere Funktionsform
extremer Punkt	auffällige Beobachtung	Daten prüfen / Sensitivitätsanalyse
hoher VIF	Kollinearität	theoretisch begründet reagieren
Konvergenzwarnung	instabile Optimierung	Skalierung / Struktur prüfen
Singularität	zu komplexe Random Effects	Random Effects prüfen

Was man auf gar keinen Fall tun sollte



Transparenz

- Probleme dürfen und sollten berichtet werden!
- „Eine einflussreiche Beobachtung wurde identifiziert. Die Analyse wurde daher mit und ohne diese Beobachtung durchgeführt. Die Richtung und Interpretation des Effekts blieb unverändert.“
- „Die maximal spezifizierte Random-Effects-Struktur führte zu einem singular fit. Daher wurde der nicht unterstützte Random Slope entfernt.“